Modelo de previsão de carga para o Programa Mensal da Operação – ForecastPMO

Sumário

1. Introdução 3
2. Algoritmos de previsão implementados no ForecastPMO 5
2.1 Método de Holt-Winters 5
2.2 Modelos ETS 6
2.3 Modelo SARIMA 7
2.4 Regressão dinâmica 10
2.5 Máquina de Vetores de Suporte - SVM 11
3. Conciliação de previsões semanais e mensais 14
3.1. Conciliação das previsões pelo método simplificado 14
3.2. Conciliação da previsão do primeiro mês do horizonte de previsão na REV0 14
3.3. Conciliação das previsões pelo método MinT 15
3.3.1 Conciliação pelo método MinT na REV0 15
3.3.2 Conciliação pelo método MinT nas demais revisões do PMO 16
4. Combinação de previsões 18
5. Especificação dos modelos de previsão de carga 20
5.1 Introdução 20
5.2 Modelos para previsão da carga semanal 20
5.2.1 Especificação do modelo de regressão dinâmica 20
5.2.2 Especificação da máquina de vetores de suporte 21
5.2.2.1 Modelo para previsão da carga na primeira semana do horizonte 21
5.2.2.2 Modelo para previsão da carga para além da primeira semana do horizonte 21
5.2.3 Especificação do modelo ETS 22
5.3 Modelos para previsão da carga mensal 22
5.3.1 Especificações do modelo de regressão dinâmica 22
5.3.2 Especificações da máquina de vetores de suporte 23
5.3.3 Especificação do modelo de Holt-Winters 23
5.3.4 Especificação do modelo SARIMA 24
6. Programa ForecastPMO 25
6.1 Instalação 25
6.2 Dados de entrada 25
6.3 Execução de modelo de previsão via console R/R Studio 27
6.3.1 Ajuste de modelos de regressão dinâmica 28
6.3.2 Ajuste de modelos SVM 32
6.3.3 Ajuste de modelos SARIMA/ETS 34
6.4 Execução da combinação de previsões 35
Referências bibliográficas 38

1. Introdução

As previsões de carga com horizonte de até dois meses e resolução temporal semanal (semana operativa) para o primeiro mês constituem informações fundamentais para a elaboração do Programa Mensal de Operação (PMO), conduzido pelo Operador Nacional do Sistema Elétrico (ONS). Nesse contexto, as previsões semanais de carga são atualizadas a cada semana, incorporando os registros mais recentes de consumo e as informações disponíveis para o horizonte de previsão. Com o objetivo de agilizar esse processo e atender às necessidades operacionais do PMO, foi desenvolvido o programa ForecastPMO, implementado em ambiente R (R CORE TEAM, 2017).

O ForecastPMO disponibiliza quatro modelos para previsão da carga mensal e três modelos para previsão da carga semanal, permitindo a construção de 12 combinações distintas de modelagens. Essas combinações, apresentadas na Tabela 1, são identificadas por um código numérico que constitui um dos parâmetros de controle do programa. Cada código corresponde a um par de modelos, sendo um destinado à previsão mensal e outro à previsão semanal.

Tabela 1. Modelos de previsão disponibilizados pelo ForecastPMO

Modelos de previsão		Previsores semanais		
		SVM	Regressão dinâmica	ETS
Previsores mensais	SVM	Modelo 0	Modelo 4	Modelo 8
	Holt-Winters	Modelo 1	Modelo 5	Modelo 9
	Regressão dinâmica	Modelo 2	Modelo 6	Modelo 10
	Sarima	Modelo 3	Modelo 7	Modelo 11

Ao término da execução de cada combinação de modelos, o ForecastPMO realiza a reconciliação entre as previsões semanais e a previsão mensal correspondente ao primeiro mês do horizonte. Esse procedimento assegura a coerência entre as duas escalas temporais, de modo que a previsão mensal seja compatível com a média ponderada das previsões semanais que compõem o período. Na literatura de séries temporais, esse procedimento é conhecido como reconciliação de previsões (*forecast reconciliation*), conforme discutido em Hyndman e Athanasopoulos (2021). O fluxograma que representa as etapas de processamento de cada combinação de modelos é apresentado na Figura 1.

Essa flexibilidade permite gerar um conjunto diversificado de previsões, a partir do qual podem ser construídos ensembles de modelos. Com o propósito de explorar a complementaridade entre as diferentes especificações e, potencialmente, aprimorar a acurácia das previsões de carga utilizadas no PMO, o ForecastPMO disponibiliza funcionalidades para combinar as previsões individuais produzidas pelos modelos. O procedimento de combinação está ilustrado na Figura 2.

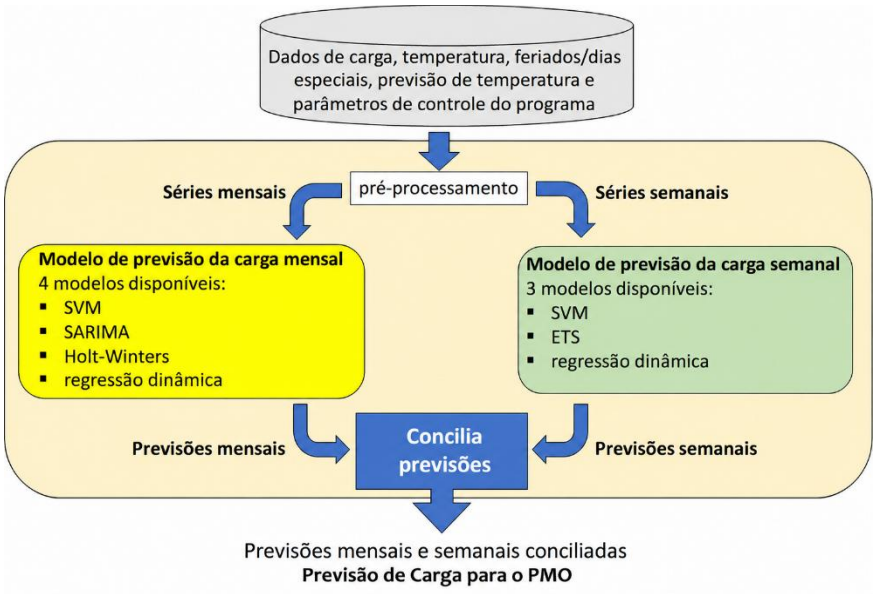


Figura 1. Fluxograma do processamento de um modelo de previsão de carga

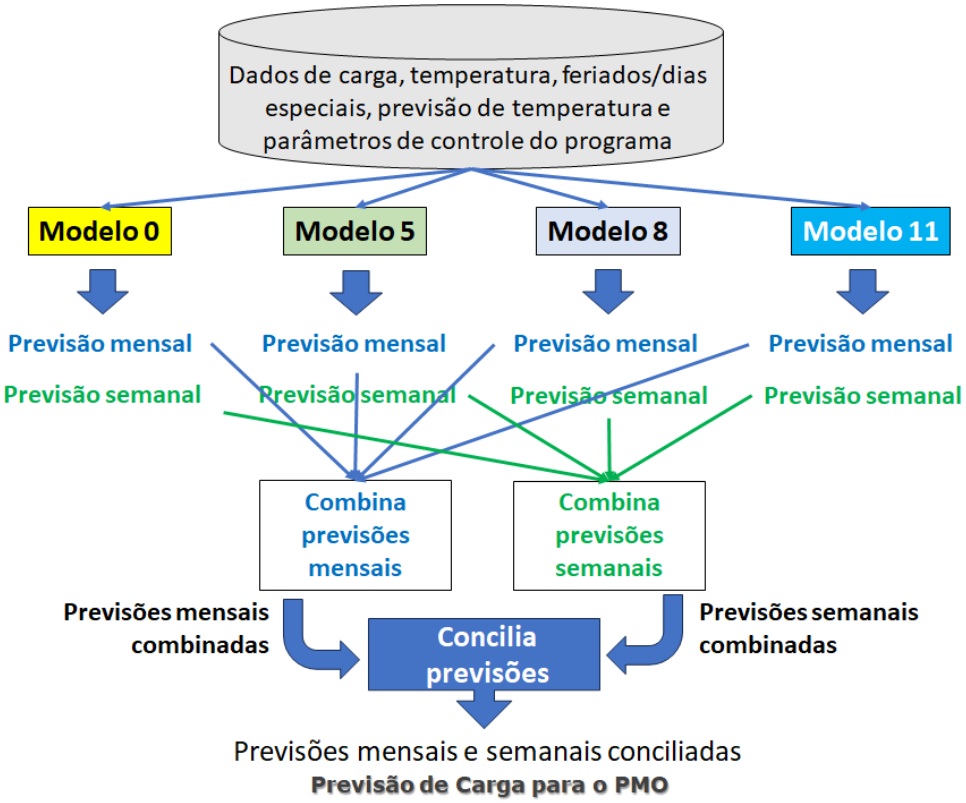


Figura 2. Fluxograma da combinação de previsões de carga

O presente texto tem por objetivo descrever os fundamentos metodológicos e os procedimentos implementados no ForecastPMO, bem como fornecer orientações para sua instalação, configuração e utilização. Para tanto, o texto está organizado em seis seções. Na Seção 2, são apresentados os fundamentos dos métodos de previsão empregados no programa, abrangendo máquinas de vetores de suporte (SVM), regressão dinâmica, modelos SARIMA, ETS e Holt-Winters (CHEN et al., 2004; HAMEL, 2009; HONG, 2009; BAGHEL et al., 2016; HYNDMAN e ATHANASOPOULOS, 2021). Na Seção 3, descreve-se o procedimento de reconciliação entre as previsões semanais e a previsão mensal referente ao primeiro mês do horizonte. Na Seção 4, são apresentados os métodos de combinação de previsões implementados no ForecastPMO. A Seção 5 detalha as especificações dos modelos utilizados na previsão das cargas semanal e mensal. Por fim, a Seção 6 apresenta as instruções para instalação, configuração e utilização do programa.

2. Algoritmos de previsão implementados no ForecastPMO

O ForecastPMO baseia-se em algoritmos estatísticos e de aprendizado de máquina, o programa emprega vários métodos de previsão de séries temporais: regressão dinâmica, modelo ETS/Holt-Winters, modelo SARIMA e máquina de vetores de suporte para regressão – SVM (*Support Vectors Machine*) ou SVR (*Support Vectors Regression*). A seguir tem-se uma breve apresentação dos métodos de previsão supracitados.

2.1 Método de Holt-Winters

Dentre os principais métodos para obtenção de previsões mensais, destaca-se o método de Holt-Winters, pertencente à família dos modelos de suavização exponencial (MAKRIDAKIS et al., 2018). O método permite que os dados sejam modelados por componentes de nível, tendência e sazonalidade, atualizadas por meio da suavização exponencial. No método de Holt-Winters com sazonalidade aditiva a previsão *h* passos à frente é obtida pela equação (1), em que L_t e T_t denotam as componentes de nível e tendência e S_{t+h-12} a componente de sazonalidade.

$$\hat{Z}_{t+h} = L_t + T_t h + S_{t+h-12} \quad (1)$$

As componentes nível, tendência e sazonalidade são atualizadas a cada nova observação pelas equações (2), (3) e (4), respectivamente.

$$L_t = \alpha(Z_t - S_{t-12}) + (1 - \alpha)(L_{t-1} + T_{t-1}) \quad (2)$$
$$T_t = \beta(L_t - L_{t-1}) + (1 - \beta)T_{t-1} \quad (3)$$
$$S_t = \gamma(Z_t - L_{t-1} - T_{t-1}) + (1 - \gamma)S_{t-12} \quad (4)$$

Em (2), (3) e (4) as constantes de suavização α, β e γ são hiperparâmetros, cujos valores estão limitados ao intervalo [0,1] e devem ser ajustados de forma a minimizar a raiz quadrada da média dos quadrados dos desvios entre os valores previstos e observados, i.e., minimizar o RMSE (*root mean square error*).

Alternativamente, na versão do método de Holt-Winters com sazonalidade multiplicativa a previsão *h* passos à frente, $\hat{Z}_{t+h}$, é obtida pela equação (5) indicada abaixo:

$$\hat{Z}_{t+h} = (L_t + T_t h)S_{t+h-12} \quad (5)$$

Neste caso, as componentes nível, tendência e sazonalidade são atualizadas a cada nova observação pelas equações (6), (7) e (8), respectivamente.

$$L_t = \alpha(Z_t/S_{t-12}) + (1 - \alpha)(L_{t-1} + T_{t-1}) \quad (6)$$
$$T_t = \beta(L_t - L_{t-1}) + (1 - \beta)T_{t-1} \quad (7)$$
$$S_t = \gamma[Z_t/(L_{t-1}+T_{t-1})] + (1 - \gamma)S_{t-12} \quad (8)$$

O desempenho do método de Holt-Winters pode ser aprimorado com a introdução de uma tendência amortecida (HYNDMAN 3 ATHANASOPOULOS, 2021). Por exemplo, na versão do método de Holt-Winters com sazonalidade aditiva e com tendência amortecida, a previsão *h* passos à frente é dada pela equação (9) e as componentes são atualizadas pelas equações (10), (11) e (12).

$$\hat{Z}_{t+h} = L_t + T_t(\phi + \phi^2 + \ldots + \phi^h) + S_{t+h-12} \quad (9)$$
$$L_t = \alpha(Z_t - S_{t-12}) + (1 - \alpha)(L_{t-1} + \phi T_{t-1}) \quad (10)$$
$$T_t = \beta(L_t - L_{t-1}) + (1 - \beta)\phi T_{t-1} \quad (11)$$
$$S_t = \gamma(Z_t - L_{t-1} - \phi T_{t-1}) + (1 - \gamma)S_{t-12} \quad (12)$$

De maneira análoga, na variante do método de Holt-Winters com sazonalidade multiplicativa e com tendência amortecida, a previsão *h* passos à frente é dada pela equação (13) e as componentes são atualizadas pelas equações (14), (15) e (16).

$$\hat{Z}_{t+h} = [L_t + T_t(\phi + \phi^2 + \ldots + \phi^h)]S_{t+h-12} \quad (13)$$
$$L_t = \alpha(Z_t/S_{t-12}) + (1 - \alpha)(L_{t-1} + \phi T_{t-1}) \quad (14)$$
$$T_t = \beta(L_t - L_{t-1}) + (1 - \beta)\phi T_{t-1} \quad (15)$$
$$S_t = \gamma[Z_t/(L_{t-1}+\phi T_{t-1})] + (1 - \gamma)S_{t-12} \quad (16)$$

2.2 Modelos ETS

Conforme indicado na seção 2.1, no modelo de Holt-Winters a equação de previsão relaciona o dado observado com componentes não observáveis (nível, tendência e sazonalidade), cujas dinâmicas são descritas pelas respectivas equações de atualização. Assim, qualquer modelo de suavização exponencial pode ser escrito como um modelo de espaço de estados. Por exemplo, o modelo de Holt-Winters com sazonalidade aditiva tem a seguinte representação em espaço de estados:

$$Z_t = L_{t-1} + T_{t-1} + S_{t-12} + \varepsilon_t \quad (17)$$
$$L_t = L_{t-1} + T_{t-1} + \alpha\varepsilon_t \quad (18)$$
$$T_t = T_{t-1} + \beta\varepsilon_t \quad (19)$$
$$S_t = S_{t-12} + \gamma\varepsilon_t \quad (20)$$

em que ε_t é um ruído branco (erro) normalmente distribuído com média 0 e variância σ^2, i.e., $\varepsilon_t \sim NID(0,\sigma^2)$.

Note que na equação (17) a observação Z_t é igual a soma das componentes não observáveis mais o erro ε_t, portanto, um modelo com erro, tendência e sazonalidade aditivos. Assim, o modelo Holt-Winters com sazonalidade aditiva em (1) corresponde ao modelo ETS(A,A,A) em espaço de estados, com o primeiro A representado o erro, o segundo A denotando a tendência e o terceiro A indicando o tipo de sazonalidade.

Hyndman e Athanasopoulos (2021) apresentam uma taxonomia de modelos ETS que abrange uma variedade de combinações do erro (*error*), da tendência (*trend*) e da sazonalidade (*seasonal*) em arranjos aditivos (A) e multiplicativos (M), conforme ilustrado nas Figuras 3 e 4, nas quais "Ad" significa tendência amortecida e "N" indica a ausência da componente.

ADDITIVE ERROR MODELS

Trend	Seasonal		
	N	A	M
N	$y_t = \ell_{t-1} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \alpha\varepsilon_t$	$y_t = \ell_{t-1} + s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \alpha\varepsilon_t$ $s_t = s_{t-m} + \gamma\varepsilon_t$	$y_t = \ell_{t-1}s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \alpha\varepsilon_t/s_{t-m}$ $s_t = s_{t-m} + \gamma\varepsilon_t/\ell_{t-1}$
A	$y_t = \ell_{t-1} + b_{t-1} + \varepsilon_t$ $\ell_t = \ell_{t-1} + b_{t-1} + \alpha\varepsilon_t$ $b_t = b_{t-1} + \beta\varepsilon_t$	$y_t = \ell_{t-1} + b_{t-1} + s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + b_{t-1} + \alpha\varepsilon_t$ $b_t = b_{t-1} + \beta\varepsilon_t$ $s_t = s_{t-m} + \gamma\varepsilon_t$	$y_t = (\ell_{t-1} + b_{t-1})s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + b_{t-1} + \alpha\varepsilon_t/s_{t-m}$ $b_t = b_{t-1} + \beta\varepsilon_t/s_{t-m}$ $s_t = s_{t-m} + \gamma\varepsilon_t/(\ell_{t-1} + b_{t-1})$
A_d	$y_t = \ell_{t-1} + \phi b_{t-1} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha\varepsilon_t$ $b_t = \phi b_{t-1} + \beta\varepsilon_t$	$y_t = \ell_{t-1} + \phi b_{t-1} + s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha\varepsilon_t$ $b_t = \phi b_{t-1} + \beta\varepsilon_t$ $s_t = s_{t-m} + \gamma\varepsilon_t$	$y_t = (\ell_{t-1} + \phi b_{t-1})s_{t-m} + \varepsilon_t$ $\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha\varepsilon_t/s_{t-m}$ $b_t = \phi b_{t-1} + \beta\varepsilon_t/s_{t-m}$ $s_t = s_{t-m} + \gamma\varepsilon_t/(\ell_{t-1} + \phi b_{t-1})$

Figura 3. Modelos com erros aditivos, ETS(A,.,.), (HYNDMAN e ATHANASOPOULOS, 2021)

MULTIPLICATIVE ERROR MODELS

Trend	Seasonal		
	N	A	M
N	$y_t = \ell_{t-1}(1 + \varepsilon_t)$ $\ell_t = \ell_{t-1}(1 + \alpha\varepsilon_t)$	$y_t = (\ell_{t-1} + s_{t-m})(1 + \varepsilon_t)$ $\ell_t = \ell_{t-1} + \alpha(\ell_{t-1} + s_{t-m})\varepsilon_t$ $s_t = s_{t-m} + \gamma(\ell_{t-1} + s_{t-m})\varepsilon_t$	$y_t = \ell_{t-1}s_{t-m}(1 + \varepsilon_t)$ $\ell_t = \ell_{t-1}(1 + \alpha\varepsilon_t)$ $s_t = s_{t-m}(1 + \gamma\varepsilon_t)$
A	$y_t = (\ell_{t-1} + b_{t-1})(1 + \varepsilon_t)$ $\ell_t = (\ell_{t-1} + b_{t-1})(1 + \alpha\varepsilon_t)$ $b_t = b_{t-1} + \beta(\ell_{t-1} + b_{t-1})\varepsilon_t$	$y_t = (\ell_{t-1} + b_{t-1} + s_{t-m})(1 + \varepsilon_t)$ $\ell_t = \ell_{t-1} + b_{t-1} + \alpha(\ell_{t-1} + b_{t-1} + s_{t-m})\varepsilon_t$ $b_t = b_{t-1} + \beta(\ell_{t-1} + b_{t-1} + s_{t-m})\varepsilon_t$ $s_t = s_{t-m} + \gamma(\ell_{t-1} + b_{t-1} + s_{t-m})\varepsilon_t$	$y_t = (\ell_{t-1} + b_{t-1})s_{t-m}(1 + \varepsilon_t)$ $\ell_t = (\ell_{t-1} + b_{t-1})(1 + \alpha\varepsilon_t)$ $b_t = b_{t-1} + \beta(\ell_{t-1} + b_{t-1})\varepsilon_t$ $s_t = s_{t-m}(1 + \gamma\varepsilon_t)$
A_d	$y_t = (\ell_{t-1} + \phi b_{t-1})(1 + \varepsilon_t)$ $\ell_t = (\ell_{t-1} + \phi b_{t-1})(1 + \alpha\varepsilon_t)$ $b_t = \phi b_{t-1} + \beta(\ell_{t-1} + \phi b_{t-1})\varepsilon_t$	$y_t = (\ell_{t-1} + \phi b_{t-1} + s_{t-m})(1 + \varepsilon_t)$ $\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha(\ell_{t-1} + \phi b_{t-1} + s_{t-m})\varepsilon_t$ $b_t = \phi b_{t-1} + \beta(\ell_{t-1} + \phi b_{t-1} + s_{t-m})\varepsilon_t$ $s_t = s_{t-m} + \gamma(\ell_{t-1} + \phi b_{t-1} + s_{t-m})\varepsilon_t$	$y_t = (\ell_{t-1} + \phi b_{t-1})s_{t-m}(1 + \varepsilon_t)$ $\ell_t = (\ell_{t-1} + \phi b_{t-1})(1 + \alpha\varepsilon_t)$ $b_t = \phi b_{t-1} + \beta(\ell_{t-1} + \phi b_{t-1})\varepsilon_t$ $s_t = s_{t-m}(1 + \gamma\varepsilon_t)$

Figura 4. Modelos com erros aditivos, ETS(M,.,.) (HYNDMAN e ATHANASOPOULOS, 2021)

Assumindo erros normalmente distribuídos, a estimação dos hiperparâmetros (constantes de alisamento, constante de amortecimento ϕ e estados iniciais das componentes não observáveis) é realizada por meio da maximização da verossimilhança. Conforme observado Hyndman e Athanasopoulos (2021), a verossimilhança é a probabilidade dos dados surgirem a partir do modelo especificado, logo uma verossimilhança alta está associada a um bom modelo. Ademais, a estimação por máxima verossimilhança permite o uso do critério de informação de Akaike (*Akaike Information Criteria* – AIC) na seleção da melhor especificação para o modelo ETS, entre as várias possibilidades nas Tabelas 3 e 4.

2.3 Modelo SARIMA

Um processo estocástico pode ser entendido como um modelo que descreve a estrutura de probabilidade de uma sequência de observações ao longo do tempo. Considere um processo estocástico como sendo uma família $Z=\{Z_t , t\in\mathbb{N}\}$ tal que para cada t, Z_t é uma variável aleatória.

Suponha que Z_t tenha origem em um experimento que pode ser repetido sob condições idênticas, a cada experimento obtém-se um registro dos valores de Z_t ao longo do tempo. Cada registro particular é uma realização do processo estocástico. Uma série temporal é uma realização amostral do processo estocástico, i.e., é uma amostra finita do conjunto de todas as trajetórias possíveis que podem ser geradas pelo processo estocástico. Portanto, uma série temporal com *m* observações é uma realização amostral entre todas as sequências de tamanho *m* que poderiam ser geradas por um mesmo processo estocástico.

Um processo estocástico está determinado quando são conhecidas suas funções de distribuição de probabilidade conjunta, porém, como estas não são conhecidas e dispõe-se de apenas uma amostra do processo estocástico (a série temporal observada) assumem-se as hipóteses de estacionariedade e ergodicidade do processo estocástico.

Um processo estocástico é estacionário se as suas características permanecem invariantes ao longo do tempo. Em um sentido estrito, a estacionariedade implica que as variáveis aleatórias Z_t e Z_{t+k} têm idênticas distribuições de probabilidade qualquer que seja k. Uma condição menos restritiva é a estacionariedade em sentido lato ou de segunda ordem na qual um processo estocástico é estacionário de segunda ordem quando o seu valor médio, $E(Z_t)$, e sua variância, $E[(Z_t - \mu)^2]$ forem constantes e as suas autocovariâncias, $Cov(Z_t,Z_{t+k})$, dependerem apenas do intervalo de tempo (*lag*) *k* entre as observações, ou seja:

$$E(Z_t) = E(Z_{t+k}) = \mu \ \forall \ t \tag{21}$$

$$E[(Z_t- \mu)^2] = \sigma^2 \ \forall \ t \tag{22}$$

$$Cov(Z_t,Z_{t+k}) = Cov(Z_{t+m},Z_{t+m+k}) \ \forall \ m \tag{23}$$

Entretanto, se o processo estocástico for gaussiano (Z_t segue uma distribuição normal) e estacionário em sentido lato, ele será estritamente estacionário, pois a distribuição normal é determinada unicamente em termos do primeiro e do segundo momento.

Quando se trabalha com uma série temporal extraída de um processo estocástico estacionário está-se diante de uma realização amostral que apresenta uma forma geral similar à outras amostras que poderiam ter sido extraídas o que torna possível estimar as características do processo e fazer previsões de forma bastante simples.

Um processo estocástico é ergódico quando apenas uma realização dele é suficiente para se obter todas as suas estatísticas. Todo o processo ergódico também é estacionário, pois uma realização de um processo não estacionário não poderá conter todas as informações necessárias para a especificação do processo. Assim, tendo-se como base uma determinada série temporal, gerada por um processo estocástico estacionário, onde o valor atual é dado por y_t, Box & Jenkins propõem o seguinte modelo para descrever o processo estocástico gerador da série:

$$y_t = \phi y_{t-1} + ... + \phi_p y_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - ... - \theta_q \varepsilon_{t-q} \tag{24}$$

O modelo pode ser reescrito, em termos de dois polinômios, pela seguinte equação obtida com o auxílio do operador defasagem ($B^d y_t = y_{t-d}$):

$$\left(1-\phi_1 B-\ldots-\theta_p \phi^p\right) y_t = \left(1-\theta_1 B-\ldots-\theta_q B^q\right)\varepsilon_t \quad (25)$$

em que ϕ e θ denotam os parâmetros do modelo e ε_t é um ruído branco, um processo estocástico gaussiano com média nula, variância constante e não autocorrelacionado:

$$E(\varepsilon_t)=E(\varepsilon_{t+k}) = 0 \ \forall \ t \quad (26)$$
$$E[\varepsilon_t^2] = \sigma_\varepsilon^2 \ \forall \ t \quad (27)$$
$$Cov(\varepsilon_t, \varepsilon_{t+k}) = Cov(\varepsilon_{t+m}, \varepsilon_{t+m+k}) = 0 \ \forall \ m \quad (28)$$

Na equação (25), as defasagens da variável y_t no polinômio do lado esquerdo representam a parte autorregressiva do modelo (AR), enquanto as defasagens dos choques aleatórios ε_t no polinômio do lado direito representam a parte média móvel (MA). A equação representa uma ampla classe de modelos denominados ARMA(p,q), onde p representa a ordem de defasagem do termo autorregressivo e q a ordem de defasagem do termo de média móvel. Por exemplo, para p=1 e q=0 tem-se o modelo autorregressivo de primeira ordem ou AR(1), no qual o valor da série no instante t depende somente do valor da série no instante t-1:

$$y_t = \phi_1 y_{t-1} + \varepsilon_t \quad (29)$$

Lembrando que $By_t = y_{t-1}$, a equação acima pode ser escrita como $(1-\phi_1 B)y_t = \varepsilon_t$. Fazendo p=0 e q=1 tem-se o modelo média móvel de primeira ordem ou MA(1), no qual o valor da série no instante t é a combinação linear dos ruídos brancos em t e t-1:

$$y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} \ \rightarrow \ y_t = (1-\theta_1 B)\varepsilon_t \quad (30)$$

Fazendo p=1 e q=1 obtém-se um o modelo autoregressivo - média móvel ARMA(1,1), cuja equação é apresentada a seguir:

$$y_t = \phi_1 y_{t-1} + \varepsilon_t - \theta_1 \varepsilon_{t-1} \quad \rightarrow \quad (1 - \phi_1 B) y_t = (1 - \theta_1 B)\varepsilon_t \quad (31)$$

Os três modelos supracitados são apenas exemplos da ampla família de modelos ARMA(p,q). Para se aplicar a metodologia de Box & Jenkins, a série em estudo deve ser pelo menos estacionária de segunda ordem, ou seja, a série tem que ter média, variância e covariâncias finitas e constantes. O exame de estacionaridade pode ser realizado observando-se a Função de Autocorrelação (ρ_k) ou FAC da série temporal investigada. A referida função é estimada por:

$$\hat{\rho}_k = \frac{\sum_{t=k+1}^{T} (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^{T} (y_t - \bar{y})^2} \quad (32)$$

onde *T* é o número de observações da série temporal investigada, $\bar{y}$ é a média da série temporal e *k* é a defasagem (*lag*) da autocorrelação.

A função de autocorrelação – FAC (ρ_k), em conjunto com a função de autocorrelação parcial – FACP (ϕ_{kk}), também é útil na identificação do grau dos polinômios dos termos AR e MA, i.e., na determinação de p e q na equação (25). Na Figura 5 são expostas as características teóricas das funções FAC e FACP para diferentes valores de p e q. Comparando-se as características teóricas da FAC e da FACP ilustradas na Figura 5 com as estimativas destas funções, obtidas com base na série temporal investigada, pode-se identificar o padrão teórico mais semelhante ao observado e assim determinar a ordem do modelo que melhor explica a dinâmica da série temporal investigada. Após a identificação da ordem do modelo, estimam-se os respectivos coeficientes ϕ e θ (MORETTIN e TOLOI, 2006).

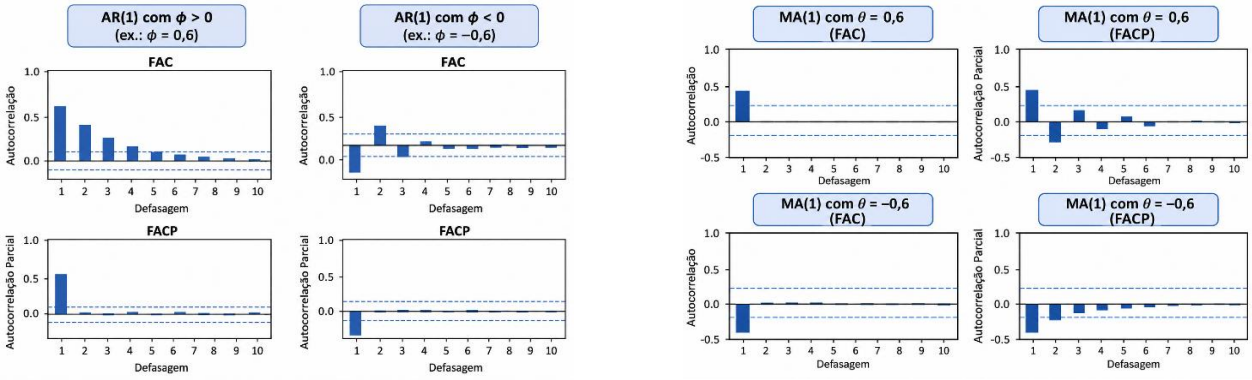


Figura 5. Padrões teóricos da FAC e da FACP (SOUZA e CAMARGO, 2004)

Se a série temporal em estudo apresentar uma componente de tendência, então o processo estocástico gerador da série é não estacionário. Neste caso a série deve passar por d diferenças simples para tornar-se estacionária, condição básica para a aplicação da metodologia Box & Jenkins. Por exemplo, para remover uma tendência linear basta tomar a primeira diferença da série (d=1):

$$\Delta y = y_t - y_{t-1} \tag{33}$$

Em algumas situações pode ser necessário tomar a segunda diferença (d=2):

$$\Delta^2 y = y_t - 2y_{t-1} + y_{t-2} \tag{34}$$

Neste caso, a metodologia Box & Jenkins é aplicada na série resultante das diferenciações e o modelo é denominado autoregressivo – média móvel – integrado ou ARIMA (p,d,q), onde d representa a ordem das diferenças simples:

$$\left(1-\phi_1 B-\ldots-\theta_p \phi^p\right)\left(1-B\right)^d y_t = \left(1-\theta_1 B-\ldots-\theta_q B^q\right)\varepsilon_t \tag{35}$$

Como antes, a identificação das ordens dos termos autorregressivos p e de médias móveis q baseia-se na análise do perfil das Funções de Autocorrelação (FAC) e Autocorrelação Parcial (FACP), porém da série obtida após as d diferenciações.

O modelo pode ser adaptado para ser aplicável em séries sazonais. No caso geral, as séries temporais podem apresentar componentes sazonais e não sazonais. Neste caso, o processo estocástico pode ser descrito pelo modelo SARIMA(p,d,q)(P,D,Q)$_s$ expresso pela seguinte equação:

$$\left(1-\phi_1 B-\ldots-\phi_p B^p\right)\left(1-\Phi_1 B^S-\ldots-\Phi_p B^{PS}\right)\left(1-B^S\right)^D\left(1-B^d\right)y_t = \left(1-\theta_1 B-\ldots-\theta_q B^q\right)\left(1-\Theta_1 B^S-\ldots-\Theta_Q B^{QS}\right)\varepsilon_t \tag{36}$$

em que

- p e q são, respectivamente, os graus dos polinômios das partes autorregressiva e de média móvel da componente não sazonal;
- P e Q são, respectivamente, os graus dos polinômios das partes autorregressiva e de média móvel da componente sazonal;
- d é a ordem das diferenças simples para remover a tendência da série
- D é a ordem das diferenças sazonais para remover a sazonalidade.
- S é o período sazonal, para séries mensais S=12.
- ϕ e θ são, respectivamente, os coeficientes das partes autorregressiva e de média móvel da componente não sazonal;
- Φ e Θ são, respectivamente, os coeficientes das partes autorregressiva e de média móvel da componente sazonal;

A diferenciação sazonal visa remover a sazonalidade da série. Dado o período sazonal S, a diferenciação sazonal é:

$$\Delta_S^D y_t = y_t - y_{t-S} \tag{37}$$

No modelo SARIMA(p,d,q)(P,D,Q)$_s$, a metodologia Box & Jenkins é aplicada na série supostamente estacionária e sem sazonalidade resultante das diferenciações simples e sazonais.

Um procedimento recomendado para identificar a melhor ordem de um modelo ARIMA consiste em identificar um modelo inicial a partir da análise das estimativas da FAC e da FACP e em seguida fazer o teste da sobrefixação (SOUZA & CAMARGO, 2004), onde são feitas várias análises para diferentes valores de p, q, P, Q a partir do modelo inicial, em especial o teste t-student para verificar a significância de cada termo adicional na ordem do modelo, considerando-se as seguintes hipóteses:

H_0: Coeficiente difere significativamente de 0

H_1: Coeficiente não difere significativamente de 0

2.4 Regressão dinâmica

Na previsão de carga busca-se uma função que permita estimar o valor da carga em um instante *t*, denotada pela variável resposta y_t, em função de um conjunto de variáveis explicativas, x_t, que incluem dados conhecidos do instante *t*, por exemplo, a temperatura prevista, o dia da semana e mês, tipo do dia (normal ou feriado) e dados passados da própria carga. Sem perda de generalidade, o modelo de regressão linear assume que a variável resposta é uma função linear de *k* variáveis explicativas (HONG *et al.*, 2010):

$$\boldsymbol{y_t = \beta_0 + \beta_1 x_{t,1} + \beta_2 x_{t,2} + \cdots + \beta_k x_{t,k} + \varepsilon_t} \tag{38}$$

em que β_0, β_1, ..., β_k denotam os coeficientes de regressão a serem estimados e ε_t denota o erro do modelo de regressão, i.e., um termo aleatório que representa a natureza estocástica da carga e o efeito de fatores não observáveis sobre a carga.

Adicionalmente, o modelo assume que o termo aleatório $\boldsymbol{\varepsilon_t}$ é um ruído branco, i.e., satisfaz as seguintes propriedades:

$$\boldsymbol{E(\varepsilon_t) = 0} \tag{39}$$
$$\boldsymbol{V(\varepsilon_t) = \sigma_\varepsilon^2 = constante} \tag{40}$$
$$\boldsymbol{E(\varepsilon_s \varepsilon_t) = 0 \; \forall \; s \neq t} \tag{41}$$

A estimação dos coeficientes de regressão (β) requer uma amostra com *n* observações da variável resposta $(\boldsymbol{y_t \; \forall \; t = 1, n})$, acompanhadas das respectivas observações nas *k* variáveis explicativas $(\boldsymbol{x_{t,1}, x_{t,2}, \ldots, x_{t,k} \forall \; t = 1, n})$. Os valores observados $\boldsymbol{y_t \; \forall \; t = 1, n}$ podem ser dispostos em um vetor *Y* e as observações das variáveis explicativas podem ser dispostas em uma matriz *X*, conforme indicado a seguir:

$$\boldsymbol{Y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \quad \boldsymbol{X} = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1k} \\ 1 & x_{21} & x_{22} & & x_{2k} \\ \vdots & & & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nk} \end{bmatrix} \tag{42}$$

em que a primeira coluna da matriz X está associada com o coeficiente β_0.

A partir das matrizes *X* e *Y* faz-se a estimação dos coeficientes de regressão pelo método dos mínimos quadrados ordinários:

$$\boldsymbol{\hat{\beta} = (X^T X)^{-1} X^T Y} \tag{43}$$

Assim, a previsão da variável resposta é dada por:

$$\boldsymbol{\hat{y}_t = \hat{\beta}_0 + \hat{\beta}_1 x_{t,1} + \hat{\beta}_2 x_{t,2} + \cdots + \hat{\beta}_k x_{t,k}} \tag{44}$$

O modelo de regressão dinâmica é uma evolução do modelo de regressão linear. Porém, de forma distinta dos modelos de regressão linear, nos modelos de regressão dinâmica o termo aleatório $\boldsymbol{\varepsilon_t}$ pode ser

autocorrelacionado e ter seu processo estocástico subjacente descrito por um modelo ARIMA. Assim, o modelo de regressão passa a ter a seguinte especificação (HYNDMAN & ATHANASOPOULOS, 2021):

$$\boldsymbol{y_t = \beta_0 + \beta_1 x_{t,1} + \beta_2 x_{t,2} + \cdots + \beta_k x_{t,k} + \eta_t} \quad (45)$$

$$\boldsymbol{(1 - \phi B)^p (1 - B)^d \eta_t = (1 - \theta B)^q \varepsilon_t} \quad (46)$$

Note que o modelo acima tem dois termos aleatórios, o erro $\boldsymbol{\eta_t}$ na equação de regressão (45) e o ruído branco $\boldsymbol{\varepsilon_t}$ do modelo ARIMA de $\boldsymbol{\eta_t}$ na equação (46).

Em função da autocorrelação nos erros, a estimação dos parâmetros do modelo é realizada por máxima verossimilhança. Adicionalmente, vale ressaltar que a variável resposta e as variáveis explicativas devem ser séries temporais estacionárias, caso contrário as séries devem ser previamente diferenciadas *d* vezes. Neste caso o modelo de regressão dinâmica passa a ser:

$$\boldsymbol{y'_t = \beta_0 + \beta_1 x'_{t,1} + \beta_2 x'_{t,2} + \cdots + \beta_k x'_{t,k} + \eta'_t} \quad (47)$$

$$\boldsymbol{(1 - \phi B)^p \eta'_t = (1 - \theta B)^q \varepsilon_t} \quad (48)$$

em que

$$\boldsymbol{y'_t = (1 - B)^d y_t} \quad (49)$$

$$\boldsymbol{x'_{t,i} = (1 - B)^d x_{t,i} \forall i = 1, k} \quad (50)$$

2.5 Máquina de Vetores de Suporte - SVM

Proposta por Vapnik (1992), o algoritmo denominado Máquinas de Vetores de Suporte - SVM pode ser usado tanto em problemas de classificação de padrões quanto em problemas de regressão (SMOLA & SCHOLKOPF, 2004), neste último caso denomina-se Regressão por Vetores de Suporte (*Support Vector Regression* – SVR).

Considere uma série temporal com *n* observações de carga y_i $\forall i$=1,*n* acompanhadas das respectivas variáveis explicativas representadas pelo vetor X_i $\forall i$=1,*n*. A previsão de carga pode ser efetuada pelo ajuste do seguinte modelo de regressão:

$$f(X) = w^T X + b \quad (51)$$

Conforme ilustrado na Figura 6a, a equação de regressão em (51) pode ser tratada como um hiperplano no centro de um hipertubo (*hypertube*) de largura 2ε com ε>0 que envolve todas as observações.



(a) Hipertubo e hiperplano de regressão (b) Variáveis de folga ξ

Figura 6. Hipertubo, hiperplano de regressão e variáveis de folga.

A melhor forma de alinhar o hipertubo aos dados consiste em posicioná-lo de maneira que as observações fiquem próximas da sua parede. O posicionamento ótimo do hipertubo é determinado pela solução do seguinte problema de programação quadrática, no qual há um par de restrições para cada observação *i*:

$$\begin{aligned} Min_{w,b} \quad & \tfrac{1}{2} w^T w \\ & y_i - (w^T X_i + b) \leq \varepsilon \; \forall \; i = 1, n \\ & (w^T X_i + b) - y_i \leq \varepsilon \; \forall \; i = 1, n \end{aligned} \quad (52)$$

Contudo, não se pode garantir que todos os dados estejam dispostos dentro de um hipertubo de largura 2ε. Para acomodar estas situações o modelo em (52) deve ser modificado com a adição de variáveis de

folga ξ indicadas no modelo em (53). Geometricamente, as variáveis de folga representam os desvios entre as paredes do hipertubo e as observações exteriores ao hipertubo, conforme indicado na Fig. 6b.

$$\begin{array}{ll} \underset{w,b.\xi^-,\xi^+}{Min} & \frac{1}{2}w^T w + C\sum_{i=1}^{n}(\xi_i^+ + \xi_i^-) \\ & y_i - (w^T X_i + b) \quad \leq \xi_i^+ + \varepsilon \;\; \forall\, i = 1,n \\ & (w^T X_i + b) - y_i \quad \leq \xi_i^- + \varepsilon \;\forall\, i = 1,n \\ & \xi_i^-, \xi_i^+ \quad \geq 0 \qquad \forall\, i = 1,n \end{array} \tag{53}$$

No problema de otimização em (53) a constante C é positiva e permite controlar o *trade-off* entre a maximização da margem e a minimização das variáveis de folga, um mecanismo de prevenção ao sobreajuste (*overfitting*). A solução do problema de otimização em (53) na sua forma dual em (54) é mais simples de ser alcançada (HAMEL, 2009).

$$\begin{array}{ll} \underset{\lambda_i^+,\lambda_i^-}{Max} & -\frac{1}{2}\sum_{i=1}^{n}\sum_{j=1}^{n}(\lambda_i^+ - \lambda_i^-)\left(\lambda_j^+ - \lambda_j^-\right)X_i^T X_j + \sum_{i=1}^{n} y_i(\lambda_i^+ - \lambda_i^-) - \varepsilon\sum_{i=1}^{n}(\lambda_i^+ - \lambda_i^-) \\ s.a. & \sum_{i=1}^{n}(\lambda_i^+ - \lambda_i^-) = 0 \\ & 0 \leq \lambda_i^+, \lambda_i^- \leq C \end{array} \tag{54}$$

em que λ denota os multiplicadores de Lagrange associados com as restrições do problema de otimização em (53), os vetores de suporte correspondem às observações X_i com multiplicadores de Lagrange não nulos.

As relações entre as soluções dos problemas primal em (53) e dual em (54) são estabelecidas pelas equações (55) e (56) a seguir, nas quais apenas os vetores de suporte contribuem:

$$w = \sum_{i=1}^{n}(\lambda_i^+ - \lambda_i^-)\, X_i \tag{55}$$

$$b = \frac{1}{n}\sum_{i=1}^{n} w^T\, X_i - y_i \tag{56}$$

Substituindo a equação (55) em (51) tem-se a seguinte equação de previsão para uma entrada *X*:

$$f(X) = \sum_{i=1}^{n}(\lambda_i^+ - \lambda_i^-)\, X_i^T X + b \tag{57}$$

Uma vantagem do algoritmo SVR é a facilidade com que se pode estender o modelo de regressão linear no modelo de regressão não linear. A transformação da equação de previsão em (57) e do problema de programação matemática em (54) para o caso não linear consiste em substituir o produto $X_i^T X_j$ por uma função núcleo (*kernel trick*) que mapeia o espaço de entrada em um espaço de maior dimensão:

$$\Phi\left(X_i, X_j\right) = \phi(X_i)\phi\left(X_j\right) \tag{58}$$

O modelo de regressão resultante é ilustrado a seguir em (59). Na sequência, em (60) tem-se a equação de previsão para o caso não linear:

$$\begin{array}{ll} \underset{\lambda_i^+,\lambda_i^-}{Max} & -\frac{1}{2}\sum_{i=1}^{n}\sum_{j=1}^{n}(\lambda_i^+ - \lambda_i^-)\left(\lambda_j^+ - \lambda_j^-\right)\Phi\left(X_i^T X_j\right) + \sum_{i=1}^{n} y_i(\lambda_i^+ - \lambda_i^-) - \varepsilon\sum_{i=1}^{n}(\lambda_i^+ - \lambda_i^-) \\ s.a. & \sum_{i=1}^{n}(\lambda_i^+ - \lambda_i^-) = 0 \\ & 0 \leq \lambda_i^+, \lambda_i^- \leq C\eta_i \end{array} \tag{59}$$

$$f(X) = \sum_{i=1}^{n}(\lambda_i^+ - \lambda_i^-)\, \Phi(X_i^T X) + b \tag{60}$$

Os resultados de uma SVM para regressão são sensíveis à definição dos seus hiperparâmetros, um conjunto formado pela constante C, pela largura do tubo ε e pela função núcleo (*kernel*). No ForecastPMO a definição dos valores ótimos para os hiperparâmetros é realizada por meio de validação cruzada ou *k-fold cross validation* (YADAV & SHUKLA, 2016).

3. Conciliação de previsões semanais e mensais

No ForecastPMO as previsões mensais e semanais da carga são realizadas separadamente por distintos modelos de previsão. Ao final da execução, o programa realiza a conciliação entre previsões semanais e a previsão mensal para o primeiro mês, de tal forma que a previsão de carga para o primeiro mês coincida com a média ponderada das previsões semanais no mesmo período, um procedimento conhecido como reconciliação de previsões (HYNDMAN e ATHANASOPOULOS,2021). Conforme ilustrado na Tabela 2, as opções de reconciliação disponibilizadas no ForecastPMO dependem do tipo de revisão do PMO.

Tabela 2. Reconciliação das previsões para o primeiro mês

Tipo da revisão do PMO	Opções de reconciliação de previsões semanais e mensais		
	Reconciliação pelo método simplificado	Reconciliação pelo método do traço mínimo (MinT *Minimum Trace*)	Reconciliação da previsão mensal
REV0	As previsões semanais são ajustadas à previsão mensal para o primeiro mês. (seção 3.1)	Ajuste simultâneo da previsão mensal e das previsões semanais para o primeiro mês. (seção 3.3)	A previsão mensal para o primeiro mês é a média ponderada das previsões semanais. (seção 3.2)
Demais revisões semanais	A previsão mensal do primeiro mês é atualizada com base nas cargas verificadas e nas previsões das demais semanas do mês. (seção 3.1)	Ajuste simultâneo das previsões semanais e da previsão para o primeiro mês, considerando imutáveis as cargas verificadas ao longo do primeiro mês. (seção 3.3)	

3.1. Conciliação das previsões pelo método simplificado

A reconciliação das previsões pelo método simplificado ajusta as previsões semanais no caso da REV0 ou ajusta a previsão mensal para o primeiro mês no caso das demais revisões semanais.

No caso da REV0 as previsões semanais (*prev_sem*) são ajustadas à previsão mensal (*prev_mês*) para o primeiro mês do horizonte. Assim, as previsões semanais ajustadas (*prev_sem_aj*) são obtidas por meio do seguinte ajuste:

$$prev_sem_aj_k = prev_sem_k \times \frac{prev_mês}{\left(\frac{\sum_{j \in mês} dias_j \times prev_sem_j}{\sum_{j \in mês} dias_j}\right)} \quad (61)$$

em que $prev_sem_k$ é a previsão de demanda para a semana k, $prev_sem_aj_k$ é o respectivo valor ajustado e $dias_j$ é o total de dias da semana j no primeiro mês ($j \in mês$).

No caso das demais revisões semanais, a previsão mensal para o primeiro mês (*prev_mês*) é dada pela média ponderada das previsões semanais (*prev_sem*) e das demandas médias verificadas nas semanas anteriores (*hist_sem*). Assim, a previsão mensal ajustada (*prev_mes*) para o primeiro mês é igual a:

$$prev_mês = \frac{\sum_{j \in mês} dias_j \times hist_j \times [1 - I(j)] + dias_j \times prev_sem_j \times I(j)}{\sum_{j \in mês} dias_j} \quad (62)$$

em que $I(j)$ é uma variável indicadora que vale 1 se semana j pertence ao horizonte de previsão e 0, caso contrário, $prev_sem_j$ é a previsão de demanda para a semana j ($I(j)=1$), $hist_j$ é demanda média verificada da semana j pertencente ao histórico ($I(j)=0$) e $dias_j$ é o total de dias da semana j no primeiro mês ($j \in mês$).

3.2. Conciliação da previsão do primeiro mês do horizonte de previsão na REV0

Neste caso, a previsão mensal para o primeiro mês do horizonte da REV0 (*prev_mês*) é dada pela média ponderada das previsões semanais, conforme indicado em (63).

$$prev_mês = \frac{\sum_{j \in mês} dias_j \times prev_sem_j}{\sum_{j \in mês} dias_j} \quad (63)$$

em que $prev_sem_j$ é a previsão de demanda para a semana j e $dias_j$ é o total de dias da semana j no primeiro mês do horizonte de previsão ($j \in mês$).

3.3. Conciliação das previsões pelo método MinT

3.3.1 Conciliação pelo método MinT na REV0

A reconciliação das previsões pelo método MinT ajusta tanto a previsão mensal para o primeiro mês quanto as respectivas previsões semanais, independentemente do tipo da revisão semanal. Contudo, de forma distinta da REV0, nas demais revisões semanais observam-se demandas verificadas nas semanas anteriores à revisão e que não podem ser modificados. Por esta razão, na REV0 aplica-se o método MinT em sua forma original (HYNDMAN e ATHANASOPOULOS, 2021), enquanto nas demais revisões semanais utiliza-se a adaptação do MinT proposta por Zhang et al. (2023).

O consumo mensal pode ser expresso como a soma do consumo semanal, conforme a seguir:

$$dias_mês \times prev_mês = \sum_{j \in mês} dias_semana_j \times prev_semana_j \tag{64}$$

Fazendo $y_{mês} = dias_mês \times prev_mês$ e $y_j = dias_semana_j \times prev_semana_j \ \forall \ j \in$ mês, tem-se que:

$$y_{mês} = \sum_{j \in mês} y_j \tag{65}$$

As equações (64) e (65) evidenciam a estrutura hierárquica entre a previsão mensal e as previsões semanais, tal estrutura pode ser expressa pela seguinte notação matricial, considerando *s* semanas no primeiro mês:

$$\begin{bmatrix} y_{mês} \\ y_1 \\ y_2 \\ \vdots \\ y_s \end{bmatrix} = \begin{bmatrix} 1 & 1 & \dots & 1 \\ 1 & 0 & & 0 \\ 0 & 1 & & 0 \\ \vdots & & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_s \end{bmatrix} \tag{66}$$

Em uma notação mais compacta tem-se que

$$Y = Sb \tag{67}$$

em que *Y* é o vetor com a previsão do consumo mensal para o primeiro mês e todas as respectivas previsões semanais, *S* é a matriz soma (*summing matrix*) e *b* é o vetor com as previsões dos consumos semanais. Note que a primeira linha da matriz *S* representa a equação (65) e as demais linhas formam uma matriz identidade de ordem igual ao número de previsões semanais.

Inicialmente, o ForecastPMO gera previsões mensais e semanais de forma independente e que não satisfazem necessariamente a equação (65), tais previsões são denominadas por previsões de base (*base forecasts*) e podem ser organizadas no vetor $\hat{Y}^T = (\widehat{y_{mês}}, \widehat{y_1}, \widehat{y_2}, \dots, \widehat{y_s})$.

Assim, as previsões reconciliadas $\tilde{Y}^T = (\widetilde{y_{mês}}, \widetilde{y_1}, \widetilde{y_2}, \dots, \widetilde{y_s})$ ou *coherent forecasts* podem ser obtidas pelo seguinte produto matricial:

$$\tilde{Y} = SG\hat{Y} \tag{68}$$

em que *G* é a matriz que mapeia as previsões de base $\hat{Y}$ nas previsões semanais, e S é a matriz que soma as previsões semanais usando a estrutura hierárquica para produzir as previsões reconciliadas $\tilde{Y}$.

No caso em tela, a matriz G tem a seguinte estrutura, onde a primeira coluna de G é formada por zeros e as demais colunas formam uma matriz identidade de ordem igual ao número de semanas no primeiro mês. Portanto, a matriz G seleciona as previsões base que serão somadas para formar a previsão mensal.

$$G = \begin{bmatrix} 0 & 1 & 0 & & 0 \\ 0 & 0 & 1 & & 0 \\ \vdots & & & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 1 \end{bmatrix} \quad (69)$$

A matriz *G* pode ser otimizada de forma a produzir previsões reconciliadas mais precisas (HYNDMAN e ATHANASOPOULOS, 2021). Por exemplo, no método MinT proposto por Wickramasuriya et al. (2019) a matriz *G* é determinada de forma a minimizar a variância total das previsões.

$$G = (S^T W^{-1} S)^{-1} S^T W^{-1} \quad (70)$$

A matriz *W* representa a matriz de covariância dos erros das previsões de base, contudo sua estimativa é difícil. Hyndmam e Athanasopoulos (2021) apresentam algumas aproximações usadas na prática que, em geral, assumem uma matriz *W* diagonal com elementos diferentes escolhidos de forma *ad hoc* ou com base nas variâncias dos resíduos das previsões de base. No caso do ForecastPMO foram conduzidos alguns experimentos e optou-se por fazer W como uma matriz diagonal, o primeiro elemento da diagonal principal foi fixado em 50, enquanto os demais, correspondendo a cada semana do horizonte, foram atribuídos valores iguais a 2 para semanas sem feriados e 7 para semanas com feriados. As previsões reconciliadas para os consumos resultam do seguinte produto:

$$\tilde{Y} = S(S^T W^{-1} S)^{-1} S^T W^{-1} \hat{Y} \quad (71)$$

Já as previsões reconciliadas para as demandas médias são dadas por:

- Previsão da demanda média mensal do primeiro mês = $\frac{\widetilde{y_{mês}}}{\boldsymbol{dias_mês}}$ (72)
- Previsão da demanda média da semana operativa s = $\frac{\widetilde{y_s}}{\boldsymbol{dias_semana_s}}$ (73)

3.3.2 Conciliação pelo método MinT nas demais revisões do PMO

Nas revisões das demais semanas operativas as demandas das semanas anteriores à revisão são conhecidas e não podem ser modificadas pela reconciliação das previsões. Portanto, neste caso, os elementos do vetor $Y^T = (y_{mês}, y_1, y_2, \dots, y_s)$ correspondentes às semanas operativas passadas não devem ser modificados. Para esta situação Zhang et al. (2023) propõem uma adaptação do método MinT. Inicialmente os autores propõem a partição do vetor Y^T em três partes, conforme indicado a seguir:

$$Y^T = (y_{mês}, v_1, \dots, v_{s-k}, u_1, \dots, u_k) \quad (74)$$

em que $y_{mês}$ representa a previsão do consumo para o primeiro mês, *v* denota as previsões para os consumos semanais (previsões a serem reconciliadas) e *u* os consumos das semanas anteriores à data da revisão e que não podem ser modificados pelo processo de reconciliação. Sem perda de generalidade, as *k* demandas conhecidas foram deslocadas para o final do vetor em (72).

Ademais, Zhang et al. (2023) propõem a partição da matriz S (su*mming matrix*):

$$S = \begin{bmatrix} S_1 & S_2 \\ I_{(s-k)\times(s-k)} & 0_{(s-k)\times k} \\ 0_{k\times(s-k)} & I_{k\times k} \end{bmatrix} \quad (75)$$

em que S_1 e S_2 são vetores formado por elementos iguais a 1 de dimensões 1x(*s*-*k*) e 1x*k*, respectivamente, enquanto 0 denota uma matriz de zeros e I denota uma matriz identidade.

A previsões reconciliadas são obtidas pela expressão a seguir:

$$\tilde{Y} = S\hat{G}\hat{Y} \quad (76)$$

em que a matriz $\hat{G}$ é dada por:5

$$\hat{G} = \begin{bmatrix} \left(\tilde{S}_1^{\,T} W^{-1} \tilde{S}_1\right)^{-1} \tilde{S}_1^{\,T} W^{-1} & 0_{(s-k)\times k} \\ 0_{k\times(s-k)} & I_{k\times k} \end{bmatrix} \left(I_{(s+1)\times(s+1)} - \begin{bmatrix} 0_{1\times(s+1-k)} & S_2 \\ 0_{s\times(s+1-k)} & 0_{s\times k} \end{bmatrix} \right) \quad (77)$$

onde $\tilde{S}_1 = \begin{bmatrix} S_1 \\ I_{(s-k)\times(s-k)} \end{bmatrix}$ e *W* representa a matriz de covariância dos erros das previsões de base, conforme discutido na seção 3.1. No caso do ForecastPMO foram conduzidos alguns experimentos e optou-se por fazer W como uma matriz diagonal. O primeiro elemento da diagonal principal é igual ao total de dias do primeiro mês (o mês corrente no caso das demais revisões do PMO), e para os demais elementos, representando cada semana do horizonte de previsão, foram atribuídos valores proporcionais aos respectivos números de dias dentro do mês corrente. Ao final, as previsões reconciliadas são calculadas pelas equações (72) e (73).

4. Combinação de previsões

No ForecastPMO as previsões mensais e semanais da carga são realizadas de forma separada por distintos modelos de previsão. As previsões semanais são produzidas por três tipos de modelos: Máquina de Vetores de Suporte (SVM), modelos ETS e modelo de regressão dinâmica. Enquanto as previsões mensais são produzidas por quatro modelos: SVM, método de Holt-Winters, modelo de regressão dinâmica e modelos de Box & Jenkins (SARIMA). No total, a combinação de 3 modelos semanais e 4 modelos mensais resulta em 12 modelos de previsão. Os 12 modelos de previsão podem ser configurados de diferentes maneiras, por exemplo, modelos com ou sem a variável temperatura, definições distintas para os hiperparâmetros dos modelos de regressão dinâmica e SARIMA, entre outras possibilidades de configuração. O resultado é que o ForecastPMO pode ser usado para gerar um *ensemble* de previsões de carga.

Visando aprimorar a acurácia da previsão de carga para o PMO e aproveitando que o ForecastPMO pode gerar um *ensemble* de previsões, propõe-se a combinação das previsões por meio do *stacking* (Wang et al., 2023), uma estratégia de aprendizado de máquina que combina as previsões de vários modelos base, também conhecidos como modelos de primeiro nível ou aprendizes base (*base learners*), para obter uma previsão final. Isso envolve treinar os modelos disponibilizados no ForecastPMO com o mesmo conjunto de dados de treinamento e, em seguida, inserir as previsões em um modelo de nível superior, também conhecido como meta modelo ou modelo de segundo nível, para fazer a previsão final, conforme indicado na Figura 7. A ideia principal por trás do *stacking* é combinar as previsões de diferentes modelos base para obter um desempenho preditivo melhor que o obtido utilizando um único modelo.

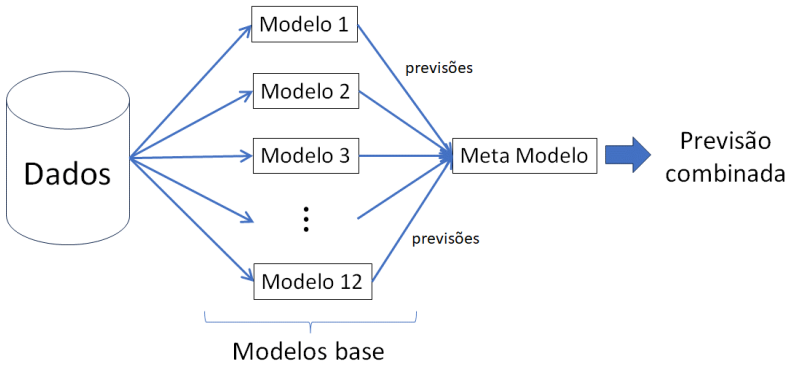


Figura 7. *Stacking* de previsões

O meta modelo pode ser especificado de diversas formas, por exemplo, modelo de regressão linear, SVM (TAN et al., 2020), redes neurais artificiais (ARE et al., 2023), *random forest* e XGBOOST (SUJAN REDDY et al. 2022, ZHANG e ZHU, 2022) entre outros (BENTO et al., 2021). No ForecastPMO foi implementado apenas o SVM com *kernel* radial. Ademais, foram implementadas três estratégias de combinação que sevem de *benchmark* para o *stacking*:

- Mediana das previsões provenientes dos modelos base
- Média das previsões provenientes dos modelos base
- Média ponderada das previsões componentes em proporção inversa ao seu desempenho histórico, ignorando a dependência mútua (BATES e GRANGER, 1969), conforme indicado a seguir:

$$Previsão_combinada(t) = \frac{\sum_{i=1}^{nmodelos=12} \frac{1}{SQEs_i} Previsão(i,t)}{\sum_{i=1}^{nmodelos} \frac{1}{SQEs_i}} \quad (78)$$

em que SQE_i é a soma dos quadrados dos erros do i-ésimo modelo $\forall$ i=1,*nmodelos*.

As combinações das previsões mensais e semanais são realizadas separadamente, ao final as previsões combinadas são conciliadas, conforme indicado na Figura 8.

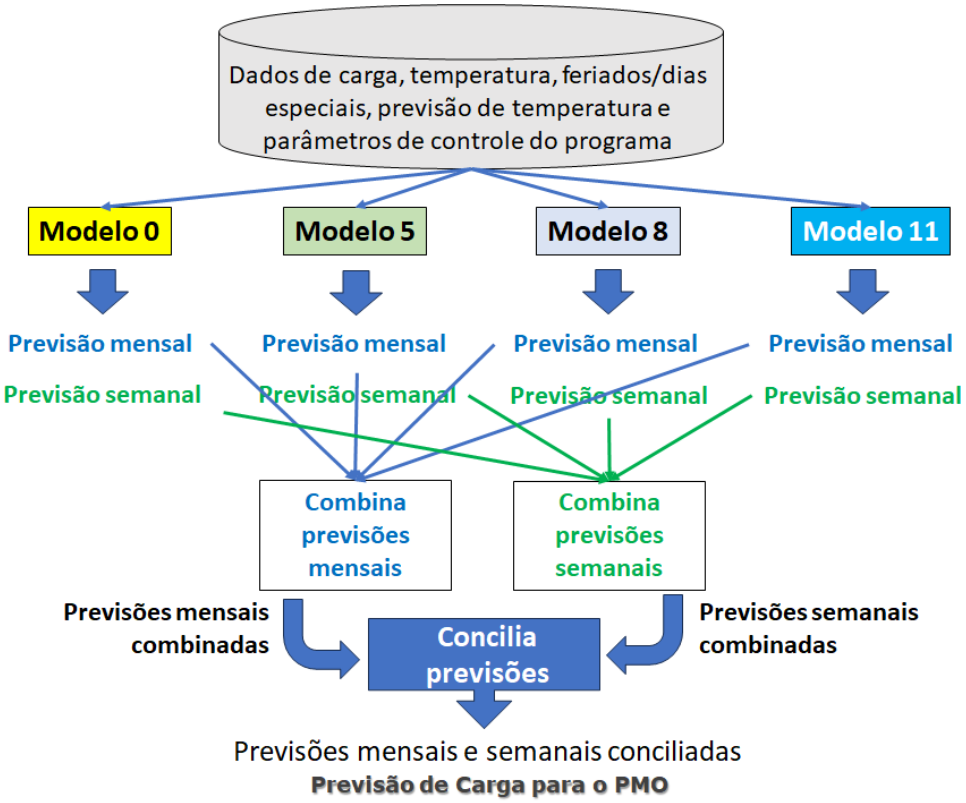


Figura 8. Fluxograma da combinação de previsões de carga

5. Especificação dos modelos de previsão de carga

5.1 Introdução

O ForecastPMO disponibiliza quatro modelos para previsão mensal (SVM, regressão dinâmica, SARIMA e Holt-Winters) e três modelos para previsão semanal (SVM, regressão dinâmica e ETS), resultando em 12 modelagens possíveis, conforme indicado na Tabela 3.

Tabela 3. Modelos de previsão disponibilizados pelo ForecastPMO

Modelos de previsão		Previsores semanais		
		SVM	Regressão dinâmica	ETS
Previsores mensais	SVM	Modelo 0	Modelo 4	Modelo 8
	Holt-Winters	Modelo 1	Modelo 5	Modelo 9
	Regressão dinâmica	Modelo 2	Modelo 6	Modelo 10
	Sarima	Modelo 3	Modelo 7	Modelo 11

5.2 Modelos para previsão da carga semanal

A previsão da carga semanal pode ser feita por regressão dinâmica, SVM ou ETS.

5.2.1 Especificação do modelo de regressão dinâmica

A previsão da carga para a primeira semana *S* do horizonte é obtida por meio do seguinte modelo de regressão dinâmica:

$$Carga_S = \beta_0 + \beta_2 temp_S + \beta_3 F_S + \beta_4 D_S + \sum_{i=1}^{K} \beta_{4+i} sen\left(\frac{2i\pi S}{52}\right) + \beta_{4+2*i} cos\left(\frac{2i\pi S}{52}\right) + \eta_t \quad (79)$$

em que:

- $temp_S$ é a temperatura máxima da semana *S*
- F_S é uma variável *dummy* para indicar a presença de feriados/dias especiais na semana *S*
- *2K* é o número de componentes harmônicas escolhido *a prori*
- η_t ~ARIMA(p,d,q)(P,D,Q), em que p,d,q,P,D,Q são definidos pelo usuário ou especificados automaticamente pelo pacote fpp3 (HYNDMAN e ATHANASOPOULOS, 2021).
- D_S é uma variável *dummy* que assume valor 1 na última semana do ano, caso contrário é zero
- β coeficientes de regressão a serem estimados

Apesar de a temperatura máxima ser destacada no modelo (78), o programa proporciona opções de modelagem adicionais, tais como a temperatura média semanal, a incorporação das temperaturas máxima e média da semana, ou a exclusão da variável temperatura do modelo de regressão.

Para as demais semanas operativas não há disponibilidade de previsões de temperatura. Porém, dado o comportamento sazonal da temperatura tomou-se a média histórica das temperaturas semanais para cada semana do ano e na sequência cada semana foi classificada em fria, normal ou quente com base nas seguintes regras:

- A semana é *quente* se a média da temperatura semanal supera a média da temperatura mais um desvio padrão da temperatura
- A semana é *fria* se a média da temperatura semanal é menor que a média da temperatura menos um desvio padrão da temperatura
- A semana é *normal* se a média da temperatura semanal pertence ao intervalo delimitado pela (média da temperatura - 1 x desvio padrão da temperatura) e (média da temperatura + 1 x desvio padrão da temperatura)

Assim, a previsão da carga semanal para uma semana S, duas ou mais semanas operativas à frente, é obtida por meio do seguinte modelo de regressão dinâmica:

$$Carga_S = \beta_0 + \beta_2 D_{Fria,S} + \beta_3 D_{Quente,S} + \beta_4 F_S + \sum_{i=1}^{K} \beta_{4+i} sen\left(\frac{2i\pi S}{52}\right) + \beta_{4+i} cos\left(\frac{2i\pi S}{52}\right) + \eta_t \quad (80)$$

em que:

- $D_{Fria,S}$ é uma variável *dummy* que indica semana com temperaturas frias
- $D_{Quente,S}$ é uma variável *dummy* que indica semana com temperaturas quentes
- F_S é uma variável *dummy* que indica a presença de feriados/dias especiais na semana *S*
- *2K* é o número de componentes harmônicas escolhido *a prori*
- η_t ~ARIMA(p,d,q)(P,D,Q), em que p,d,q,P,D,Q são definidos pelo usuário ou especificados automaticamente pelo pacote fpp3 (HYNDMAN e ATHANASOPOULOS, 2021).
- D_S é uma variável *dummy* que assume valor 1 na última semana do ano, caso contrário é zero
- β coeficientes de regressão a serem estimados

O programa permite uma especificação alternativa sem a variável temperatura, i.e., sem as variáveis $D_{Fria,S}$ e $D_{Quente,S}$.

5.2.2 Especificação da máquina de vetores de suporte

5.2.2.1 Modelo para previsão da carga na primeira semana do horizonte

A previsão da carga semanal para a primeira semana do horizonte *S*+1 (*S* é a semana operativa corrente) é obtida por meio de uma SVM com as seguintes variáveis explicativas:

- valores passados da carga nas semanas em *lags* especificados pelo usuário ou definidos automaticamente pelo programa com base na função de autocorrelação da carga.
- temperatura máxima prevista para a semana *S*+1
- mês mais frequente na semana *S*+1 (11 variáveis *dummy*)
- variável *dummy* para indicar a última semana do ano
- tendência linear, i.e., um contador do número de semanas que inicia na primeira semana do histórico
- variável *dummy* para indicar feriados em dias úteis com perfis de sábado/domingo, Natal e Ano novo na semana *S*+*h*
- variável *dummy* para indicar feriados em dias úteis com perfis de sábado/domingo, Natal e Ano novo na semana corrente (semana S)

Apesar de a temperatura máxima ser destacada no modelo, o programa proporciona opções de modelagem adicionais, tais como a temperatura média semanal, a incorporação das temperaturas máxima e média da semana, ou a exclusão da variável temperatura do modelo de regressão. Vale destacar que o ajuste do modelo SVM é realizado por meio de uma validação cruzada na qual consideram-se os *kernels* linear e sigmoide e valores 1 e 10 para a constante C. No caso da semana alvo ter feriados, escolhe-se a menor das previsões resultantes dos SVM com *kernel* linear e *kernel* sigmoide.

5.2.2.2 Modelo para previsão da carga para além da primeira semana do horizonte

Para a previsão da carga semanal da segunda semana operativa em diante não é possível contar com previsões de temperatura. O programa gera duas previsões da carga semanal para as semanas *S*+*h*, $\forall$ *h*=2,6 (*S* é a semana operativa corrente) e na sequência escolhe uma das previsões.

O primeiro conjunto de previsões da carga para as semanas *S*+*h*, $\forall$ *h*=2,6 é obtido em função das seguintes variáveis explicativas:

- valores passados da carga nas semanas em *lags* especificados pelo usuário ou definidos automaticamente pelo programa com base na função de autocorrelação da carga.
- mês mais frequente na semana *S*+*h* (11 variáveis *dummy*)
- tendência linear, i.e., um contador do número de semanas que inicia com 1 na primeira semana do histórico
- variável *dummy* para indicar feriados em dias úteis com perfis de sábado/domingo, Natal e Ano novo na semana *S*+*h*
- variável *dummy* para indicar feriados em dias úteis com perfis de sábado/domingo, Natal e Ano novo na semana corrente (semana S)

Caso a semana alvo não tenha feriados, os padrões de treinamento com feriados no horizonte são retirados da amostra e a variável *dummy* para indicar feriado na semana S+h é retirada do modelo. Um novo SVM é ajustado com as variáveis a seguir:

- valores passados da carga nas semanas em *lags* especificados pelo usuário ou definidos automaticamente pelo programa com base na função de autocorrelação da carga.
- mês mais frequente na semana *S*+*h* (11 variáveis *dummy*)
- tendência linear, i.e., um contador do número de semanas que inicia com 1 na primeira semana do histórico
- variável *dummy* para indicar feriados em dias úteis com perfis de sábado/domingo, Natal e Ano novo na semana corrente (semana S)

Já o segundo conjunto de previsões da carga para as semanas *S*+*h*, $\forall$ *h*=2,6 é obtido pela seguinte equação de previsão:

$$\text{Previsão da carga na semana } S+h = (\text{carga da semana operativa corrente } S) \times \exp(r_h) \quad (81)$$

em que r_h corresponde à taxa de crescimento prevista, para a semana *S*+*h*, i.e., o logaritmo da razão da carga de duas semanas separadas por *h* semanas: r_h=ln[carga(semana *S*+*h*)/carga(semana *S*)].

A previsão da taxa de crescimento da carga *h* semanas à frente (até seis semanas à frente) é determinada em função das seguintes variáveis explicativas:

- valores passados da taxa de crescimento da carga semanal em *lags* especificados pelo usuário ou definidos automaticamente pelo programa com base na função de autocorrelação.
- variável *dummy* para indicar feriados em dias úteis com perfis de sábado/domingo, Natal e Ano novo na semana *S*+*h*
- mês mais frequente na semana *S*+*h* (11 variáveis *dummy*)
- carga da semana corrente *S*
- tendência linear, i.e., um contador do número de semanas que inicia com 1 na primeira semana do histórico
- variável *dummy* para indicar a última semana do ano

Vale destacar que o ajuste de qualquer modelo SVM para previsão semanal é realizado por meio de uma validação cruzada na qual consideram-se os *kernels* linear e sigmoide e valores 1 e 10 para a constante C. No caso da semana alvo ter feriados, escolhe-se a menor das previsões resultantes dos SVM com *kernel* linear e *kernel* sigmoide.

Os dois conjuntos de previsões são gerados e na semana alvo sem feriado o programa pega a previsão SVM mais próxima da previsão semanal gerada por um modelo ETS. Porém, em uma semana alvo com feriado, o programa escolhe a menor previsão entre as duas previsões geradas pelos modelos SVM.

5.2.3 Especificação do modelo ETS

A previsão da carga semanal pelo modelo ETS é obtida por meio do seguinte *script* R (HYNDMAN e ATHANASOPOULOS, 2021):

```
my_dcmp_spec <- decomposition_model(
                    STL(carga_sem),
                    ETS(season_adjust ~ season("N"))
    )
```
(82)

Note que o *script* em (82) aplica uma decomposição STL (CLEVELAND et al., 1990, PESSANHA e ALMEIDA, 2021) na série temporal da carga semanal (carga_sem) para remover a sazonalidade e na sequência avalia diferentes especificações para o modelo ETS que melhor se ajusta a carga semanal ajustada sazonalmente (season_adjust), i.e., avalia modelos ETS(.,.,N) com tendência e erros que podem ser aditivos ou multiplicativos e escolhe a especificação com o menor AICc (HYNDMAN e ATHANASOPOULOS, 2021).

5.3 Modelos para previsão da carga mensal

A previsão da carga semanal pode ser feita por regressão dinâmica, SARIMA, SVM ou Holt-Winters.

5.3.1 Especificações do modelo de regressão dinâmica

Na previsão da carga mensal consideram-se dois modelos de regressão dinâmica: um modelo para a previsão de carga do mês corrente, *M*, e um modelo de previsão de carga para os meses seguintes, *M*+1 e *M*+2. A diferença entre os dois modelos reside no fato de que na previsão de carga para o mês corrente pode-se contar com observações da carga diária desde o dia 1 do mês até o dia *d* de realização da previsão. Assim, para o mês corrente o modelo de regressão dinâmica tem a seguinte especificação:

$$Carga_M = \beta_0 + \beta_2 Acumulada_M + \beta_3 NDU_M + \sum_{i=1}^{11} \beta_{3+i} D_{i,M} + \eta_M \quad (83)$$

em que:

- $Acumulada_M$ é a carga entre os dias 1 e *d* do mês *M*
- NDU_M número de dias úteis no mês *M*
- $D_{i,M}$ é uma variável *dummy* mensal (sazonalidade mensal)
- η_t ~ARIMA(p,d,q)
- β coeficientes de regressão a serem estimados

Já na previsão da carga para os meses *M*+1 e *M*+2 considera-se a seguinte especificação para o modelo de regressão dinâmica:

$$Carga_M = \beta_0 + \beta_2 M + \beta_3 NDU_M + \sum_{i=1}^{11} \beta_{3+i} D_{i,M} + \eta_M \quad (84)$$

em que a variável explicativa *M* é um contador de meses e captura a tendência.

Seja $Carga_M^{(1)}$ a previsão da carga para o mês corrente *M*, obtida pelo modelo na Equação (83), e seja $Carga_M^{(2)}$, $Carga_{M+1}^{(2)}$ e $Carga_{M+2}^{(2)}$ as previsões obtidas pelo modelo na equação (84), i.e., sem considerar as observações acumuladas para o mês corrente. Dado que as observações disponíveis para o mês corrente aportam informação relevante para a previsão de carga, as previsões da carga para os meses *M*+1 e *M*+2 são corrigidas pelas equações a seguir:

$$Carga_corrigida_{M+1} = Carga_M^{(1)} \frac{Carga_{M+1}^{(2)}}{Carga_M^{(2)}} \quad (85)$$

$$Carga_corrigida_{M+2} = Carga_M^{(1)} \frac{Carga_{M+2}^{(2)}}{Carga_M^{(2)}} \quad (86)$$

5.3.2 Especificações da máquina de vetores de suporte

Tal modelo tem por finalidade fornecer previsões da carga mensal até dois meses à frente. A previsão da carga para o mês *M* é determinada em função das seguintes variáveis:

- valores passados da carga nos meses em *lags* especificados pelo usuário ou definidos automaticamente pelo programa com base na função de autocorrelação da carga.
- tendência linear, i.e., um contador do número de meses que inicia no primeiro mês do histórico

O modelo de previsão foi implementado em uma SVM com *kernel* linear e C=1. A mesma máquina é utilizada para prever os dois meses do horizonte de previsão, neste caso a previsão para o segundo mês depende da previsão para o primeiro mês à frente.

5.3.3 Especificação do modelo de Holt-Winters

No ForecastPMO são avaliadas 4 especificações do modelo de Holtp-Winters: Aditivo, Aditivo com tendência amortecida, Multiplicativo e Multiplicativo com tendência amortecida, conforme o script R a seguir:

```
fit<-dadosmensais %>%
    model(
      HWaditivo=ETS(carga_mes~error("A")+trend("A")+season("A")),
```
(87)

```
      HWAAdA=ETS(carga_mes~error("A")+trend("Ad")+season("A")),
      HWMAdM=ETS(carga_mes~error("M")+trend("Ad")+season("M")),
      HWmultiplicativo=ETS(carga_mes~error("M")+trend("A")+season("M"))
    )
selecionado=glance(fit)%>%filter(AICc==min(AICc,na.rm=TRUE))
fit=fit%>%select(selecionado$.model)
```

Conforme indicado em (87), as quatro especificações são avaliadas e seleciona-se a com o menor AICc (HYNDMAN e ATHANASOPOULOS, 2021).

5.3.4 Especificação do modelo SARIMA

As especificação dos hiperparâmetros p,d,q,P,D,Q do modelo SARIMA pode ser realizada pelo usuário ou ser obtida automaticamente pelas funções do pacote fpp3 (HYNDMAN e ATHANASOPOULOS, 2021).

6. Programa ForecastPMO

6.1 Instalação

Para instalar o ForecastPMO copie o arquivo contendo o pacote R (forecastpmo.zip) para algum diretório. Na sequência abra o R ou RStudio. Para instalar o pacote no R use a opção do menu "Pacotes/Instalar pacote(s) a partir de arquivos zip locais...". Já no RStudio escolha a opção "*Tools/Install Packages...*" e na sequência escolha a opção "*Package Archive File*" na caixa de diálogo ilustrada na Figura 9. Nos dois casos selecione o arquivo forecastpmo.zip e siga as orientações apresentadas durante o processo de instalação.

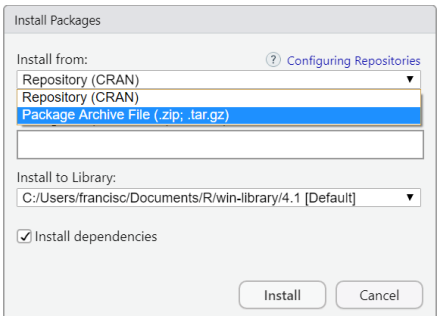


Figura 9. Caixa de diálogo aberta pelo RStudio para instalação de pacote via arquivo

O programa usa os seguintes pacotes: bizdays 1.0.17, dplyr 1.1.4, e1071 1.7.17, forecast 8.24.0, fpp3 1.0.2, tsibble 1.1.6, janitor 2.2.1 e stringr 1.6.0, os quais recomenda-se que sejam previamente instalados.

6.2 Dados de entrada

Os dados de entrada para o modelo de previsão devem ser organizados em arquivos CSV ou em *data.frames*. A seguir, na Tabela 4 tem-se a lista de arquivos CSV/data.frames esperados pelo programa.

Tabela 4. Dados de entrada para o ForecastPMO

Conteúdo	Nomes dos arquivos CSV/*data.frames*
Parâmetros de execução e modelagem	PARAMETROS, apenas para o caso de dados organizados em arquivos CSV
Dados históricos de carga	arquivo CSV com qualquer nome, mas o *data.frame* deve ser denominado por CARGAHIST
Dados históricos de temperatura	arquivo CSV com qualquer nome, mas o *data.frame* deve ser denominado por TEMPHIST
Datas de feriados e dias especiais	arquivo CSV com qualquer nome, mas o *data.frame* deve ser denominado por FERIADOS
Informações sobre o horizonte de previsão	arquivo CSV com qualquer nome, mas o *data.frame* deve ser denominado por HORIZONTE
Previsões de temperatura	arquivo CSV com qualquer nome, mas o *data.frame* deve ser denominado por TEMPPREV

O arquivo PARAMETROS.CSV deve conter o nome do subsistema e os nomes dos arquivos CSV com dados históricos de carga, série de temperatura, feriados, horizonte de previsão e séries de temperaturas previstas, como visualizado na Figura 10. No último campo (campo Parâmetros) deve-se informar 0 ou 1 para especificar o separador decimal usado nos arquivos de saída: 0 para ponto e 1 para vírgula.

	A	B	C	D	E	F	G
1	SUBSISTEMA	CARGAHIST	EXOGENAHIST	EXOGENAPREV	FERIADOS	HORIZONTE	PARAMETROS
2	SECO_2022-03-26_	SECO_2022-03-26_CARGAHIST	SECO_2022-03-26_EXOGENAHIST	SECO_2022-03-26_EXOGENAPREV	SECO_2022-03-26_FERIADOS	SECO_2022-03-26_HORIZONTE	0

Figura 10. Exemplo arquivo PARAMETROS.CSV

O arquivo CARGAHIST com dados históricos de carga deve conter a série de carga diária até o último dia da última semana operativa (MW). Adicionalmente, cada valor deve ser acompanhado da respectiva data de ocorrência, especificada em termos de ano/mês/dia. Na Figura 11 tem-se um exemplo com as

primeiras linhas do arquivo CSV e do *data.frame* com dados históricos da carga em base diária. Vale destacar que os nomes na primeira linha do CSV e os nomes das variáveis no *data.frame* devem ser os mesmos apresentados na Figura 11.

	A	B
1	Data	Carga
2	01/01/2017	32.541
3	02/01/2017	38.965
4	03/01/2017	41.023
5	04/01/2017	41.008
6	05/01/2017	41.893
7	06/01/2017	41.914
8	07/01/2017	39.201
9	08/01/2017	36.162
10	09/01/2017	42.832

(a) arquivo CSV

```
> head(deck$CARGAHIST)
        Data    Carga
1 2016/01/01 31413.08
2 2016/01/02 33268.12
3 2016/01/03 31909.46
4 2016/01/04 36782.70
5 2016/01/05 38118.87
6 2016/01/06 38792.62
```

(b) data.frame

Figura 11. Exemplos do arquivo CSV e do *data.frame* com dados da carga diária (CARGAHIST)

O arquivo TEMPHIST.CSV com dados históricos de temperatura deve conter os valores mínimos, médios e máximos diários da temperatura equivalente (°C). Adicionalmente, cada valor deve ser acompanhado da respectiva data de ocorrência, especificada em termos de ano/mês/dia. Na Figura 12 tem-se um exemplo com as primeiras linhas do arquivo CSV e do *data.frame* com dados históricos de temperatura em base diária. Vale destacar que os nomes na primeira linha do CSV e os nomes das variáveis no *data.frame* devem ser os mesmos apresentados na Figura 12.

	A	B	C	D
1	Data	Exo_TemperaturaMax	Exo_TemperaturaMed	Exo_TemperaturaMin
2	01/01/2017	33,18	28,04	23,36
3	02/01/2017	31,96	27,72	23,90
4	03/01/2017	33,00	27,67	23,92
5	04/01/2017	31,51	27,00	22,97
6	05/01/2017	31,18	26,96	23,31
7	06/01/2017	32,70	27,60	23,45
8	07/01/2017	32,70	27,72	23,37
9	08/01/2017	33,31	27,69	23,11
10	09/01/2017	32,12	27,56	23,76

(a) arquivo CSV

```
> head(deck$TEMPHIST)
        Data Exo_TmpMax Exo_TmpMed Exo_TmpMin
1 2014/01/01     32.865   27.26208     23.057
2 2014/01/02     32.915   27.52562     23.196
3 2014/01/03     33.626   28.32913     23.412
4 2014/01/04     34.040   28.64367     23.907
5 2014/01/05     32.269   27.41933     23.128
6 2014/01/06     32.587   26.89771     21.875
```

(b) data.frame

Figura 12. Exemplos do arquivo CSV e do *data.frame* com séries históricas de temperatura (TEMPHIST)

As médias horárias da temperatura equivalente (°C) devem ser informadas para o mesmo período do histórico de dados de carga.

O arquivo FERIADOS.CSV com informações de feriados e dias especiais deve informar a data de cada feriado (no formato ano/mês/dia) ao longo do período do histórico de carga e o tipo do feriado/dia especial, cuja codificação deve seguir a Tabela 5. Na Figura 13 tem-se um exemplo do arquivo CSV e do *data.frame* com dados de feriados e dias especiais. Vale destacar que os nomes na primeira linha do CSV e os nomes das variáveis no *data.frame* devem ser os mesmos apresentados na Figura 13.

Tabela 5. Codificação de feriados e dias especiais

Tipo do dia	Código
Feriado Nacional perfil sábado	1
Feriado Nacional perfil domingo	2
Segunda-feira da semana do Carnaval	3
Terça-feira da semana do Carnaval	4
Quarta-Feira de Cinzas	5
Natal ou 1° de janeiro	6
Dia após Natal ou após 1° de janeiro	7
Véspera de Natal ou véspera de 1° de janeiro	8
Véspera de feriado	9
Dia após feriado e dia especial	10
Dia especial e recesso	11
Blecaute, Jogos da Copa, etc.	12

	A	B
1	Data	Tipo
2	20/01/2017	11
3	27/02/2017	3
4	28/02/2017	4
5	01/03/2017	5
6	14/04/2017	2
7	16/04/2017	2
8	21/04/2017	2
9	01/05/2017	2
10	15/06/2017	2

(a) arquivo CSV

```
> head(deck$FERIADOS)
  Tipo       Data
1    5 2014/03/05
2    5 2015/02/18
3   12 2015/12/30
4    5 2016/02/10
5    2 2016/11/02
6   11 2016/11/14
```

(b) data.frame

Figura 13. Exemplos do arquivo CSV e do *data.frame* com dados de feriados/dias especiais (FERIADOS)

O arquivo HORIZONTE.CSV deve conter as datas dos instantes inicial e final da previsão no formato ano/mês/dia/hora/minuto e datas dos feriados no período de previsão no formato ano/mês/dia acompanhadas da indicação do tipo do feriado segundo a codificação da Tabela 6. Na Figura 14 tem-se um exemplo do arquivo HORIZONTE.CSV e do *data.frame* com informações do horizonte de previsão. Vale destacar que os nomes na primeira linha do CSV e os nomes das variáveis no *data.frame* devem ser os mesmos apresentados na Figura 14.

	A	B	C	D	E	F	G
1	Variavel	Ano	Mes	Dia	Hora	Min	Feriado.Dia.Especial
2	Instante inicial da previsao	2022	3	26	0	0	NA
3	Data final da previsao	2022	5	31	23	59	NA
4	feriado	2022	11	1	0	0	9
5	feriado	2022	11	2	0	0	1
6	feriado	2022	11	14	0	0	9
7	feriado	2022	11	15	0	0	2
8	feriado	2022	11	16	0	0	10
9	feriado	2022	11	20	0	0	1
10	feriado	2022	12	24	0	0	8
11	feriado	2022	12	25	0	0	6
12	feriado	2022	12	26	0	0	7
13	feriado	2022	12	31	0	0	8

(a) arquivo CSV

```
> deck$HORIZONTE
                        Variavel  Ano Mes Dia Hora Min Feriado.Dia.Especial
1 Instante inicial da previsao 2018  12  22    0   0                    NA
2       Data final da previsao 2019   2  28   23  59                    NA
3   Inicio do horario de verao 2018  11   4    0   0                    NA
4      fim do horario de verao 2019   2  17    0   0                    NA
5                      feriado 2018  12  24    0   0                     8
6                      feriado 2018  12  25    0   0                     6
7                      feriado 2018  12  26    0   0                     7
8                      feriado 2018  12  31    0   0                     8
```

(b) data.frame

Figura 14. Exemplos do arquivo CSV e do *data.frame* com dados do horizonte de previsão (HORIZONTE)

O arquivo TEMPPREV.CSV deve conter previsões diárias das temperaturas (°C) mínimas, médias e máximas para pelo menos até 7 dias à frente. Adicionalmente, os valores devem ser acompanhados pelas respectivas datas especificadas em termos de ano/mês/dia. Na Figura 15, tem-se um exemplo do arquivo CSV e do *data.frame* com as temperaturas previstas. Vale destacar que os nomes na primeira linha do CSV e os nomes das variáveis no *data.frame* devem ser os mesmos apresentados na Figura 15.

	A	B	C	D
1	Data	Exo_TemperaturaMax	Exo_TemperaturaMed	Exo_TemperaturaMin
2	26/03/2022	29,82	24,95	21,79
3	27/03/2022	29,64	24,88	21,71
4	28/03/2022	29,48	24,68	21,28
5	29/03/2022	29,01	24,81	20,47
6	30/03/2022	30,53	25,54	20,44
7	31/03/2022	30,78	26,01	22,66
8	01/04/2022	27,01	23,65	21,09

(a) arquivo CSV

```
> head(deck$TEMPPREV)
        Data Exo_TmpMax Exo_TmpMed Exo_TmpMin
1 2021/01/30    30.7489    26.33460    22.1342
2 2021/01/31    30.7271    26.97105    23.3137
3 2021/02/01    30.2962    26.70427    23.7061
4 2021/02/02    29.7520    25.84285    22.4666
5 2021/02/03    29.8875    26.15037    22.8610
6 2021/02/04    32.7214    27.30991    21.4323
```

(b) data.frame

Figura 15. Exemplos do arquivo CSV e do *data.frame* com previsões de temperatura (TEMPPREV)

6.3 Execução de modelo de previsão via console R/R Studio

O programa ForecastPMO disponibiliza várias opções de execução, controladas por meio dos seguintes parâmetros de execução:

- dirinput: diretório onde estão os arquivos de dados em formato CSV ou nome do *data.frame* no ambiente R
- dirout: diretório onde serão gravados os arquivos CSV com as previsões de carga

- modelo: número do modelo (0,1,2,3,4,5,6,7,8,9,10,11), conforme indicado na Tabela 2 (seção 1).

- tipoinput: (0) para dados em arquivo CSV e (1) para dados em *data.frame*

- tipotemp: (0) para temperatura máxima da semana, (1) para temperatura média da semana, (2) para temperaturas média e máxima da semana, (3) sem temperatura (*default*).

- tipoestudo: (0) para revisão PMO e (1) para o PMO (REV0)

- conciliar: seleciona o método de conciliação das previsões semanais ao valor da previsão mensal para o primeiro mês, (0) para o método simplificado (seção 3.1), (1) para o método MinT (seção 3.3) e (2) para o ajuste da previsão mensal (seção 3.2), sendo este último efetivo apenas na REV0.

- nharm: número de componentes harmônicas (*K* em (79) e (80) na seção 5.2.1) no modelo de regressão dinâmica para previsão da carga semanal (necessário apenas nos modelos 4,5,6 e 7), o valor *default* é 3.

- pandemia = 1 para tratar o efeito da pandemia sobre a carga no período de março até agosto de 2020, 0 para não tratar (*default*).

- grafico = 1 para exibir FAC, FACP e histograma e gerar arquivos CSV com previsões, 0 para não exibir e não gravar arquivos (*default*).

- hparmes = pode ser o vetor com as ordens p,d,q,P,D,Q da modelagem SARIMA do termo aleatório (erro) da regressão dinâmica (modelos 2, 6 e 10), ou pode ser o vetor com as ordens p,d,q,P,D,Q da modelagem SARIMA da carga mensal (modelos 3, 7 e 11) ou ainda as defasagens da carga (*lags*) considerada pelo SVM na previsão da carga mensal (modelos 0, 4 e 8), a opção *default* é a seleção automática.

- hparsem1 = ordens p,d,q,P,D,Q da modelagem SARIMA do termo aleatório (erro) da regressão dinâmica ajustada para previsão da carga da primeira semana operativa do horizonte (modelos 4,5,6 e 7) ou lags do modelo SVM para previsão semanal (modelos 0,1,2 e 3), a opção *default* é a seleção automática.

- hparsem2 = ordens p,d,q,P,D,Q da modelagem SARIMA do termo aleatório (erro) da regressão dinâmica ajustada para previsão da carga a partir da segunda semana operativa do horizonte (modelos 4,5,6 e 7), a opção *default* é a seleção automática.

Note que os parâmetros *tipotemp*, *nharm*, *pandemia*, *grafico*, *hparmes*, *hparsem1* e *hparsem2* contam com opções default, i.e., não precisam ser declarados explicitamente para a execução do programa.

A execução do ForecastPMO requer a especificação dos parâmetros supracitados na linha de comando a seguir:

previsorpmo(dirinput,dirout,modelo,tipoinput,tipotemp,tipoestudo,conciliar,nharm,pandemia, grafico,hparmes,hparsem1,hparsem2) (88)

A pandemia de Covid 19 alterou o perfil da carga, sobretudo no período de março de 2020 até agosto do mesmo ano. Por esta razão foi introduzida a opção de tratar o período da pandemia nos modelos de previsão da carga mensal. O tratamento depende do método utilizado, no modelo de regressão dinâmica foi introduzida uma variável *dummy* que vale 1 apenas nos meses de março até agosto de 2020 e assume valor 0 nos demais meses. Já nos modelos de Holt-Winters, SARIMA e SVM a série temporal foi modificada com a substituição da carga verificada entre março e agosto de 2020 pelas respectivas estimativas geradas por um modelo Holt-Winters aditivo ajustado até fevereiro de 2020. Para ativar o tratamento do efeito da pandemia faça pandemia=1 na chamada da função *previsorpmo*.

6.3.1 Ajuste de modelos de regressão dinâmica

A seguir, um exemplo de como chamar a função *previsorpmo* para gerar previsões semanais e mensais com modelos de regressão dinâmica (*modelo* 6), configurados com seleção automática dos hiperparâmetros (p e q) da modelagem Box & Jenkins dos termos aleatórios η_t nos modelos de previsão mensal (*hparmes*=c(NA,1,NA,0,0,0)) e previsão semanal (*hparsem1*=c(NA,1,NA,0,0,0)), ambos com 6 componentes harmônicas (*nharm*=3) e temperatura máxima (*tipotemp*=0). As previsões semanais e mensal são para REV0 (*tipoestudo*=1) e são conciliadas pelo método MinT (*conciliar*=1). Os dados estão no formato data.frame (*tipoinput*=1), especificamente no data.frame *deck*. O efeito da pandemia na carga foi ignorado (*pandemia*=0) e os resultados gráficos serão apresentados (*grafico*=1).

Quadro 1. Exemplo de *script* para execução do modelo 6 do ForecastPMO

```
load("deck_PMOFev24.Rdata") # carrega data.frame
dirinput=deck # data.frame disponível em deck_PMOFev24.Rdata
dirout="C:/ForecastPMO/resultados" # diretório para gravação dos arquivos de saída

hparmes=c(NA,1,NA,0,0,0) # o NA indica seleção automática dos hiperparâmetros p e d
hparsem1=c(NA,1,NA,0,0,0) # o NA indica seleção automática dos hiperparâmetros p e q
hparsem2=hparsem1 # o NA indica seleção automática dos hiperparâmetros p e q

resultado6=previsorpmo(dirinput,dirout,modelo=6,tipoinput=1,tipotemp=0,tipoestudo=1,conciliar=1,
nharm=3,pandemia=0,grafico=1,hparmes=hparmes,hparsem1=hparsem1,hparsem2=hparsem2)
```

Nota: (1) o que aparece após # é um comentário ignorado pelo R, (2) os hiperparâmetros marcados com NA (*not available*) são livres para serem especificados de forma automática pelo algoritmo de identificação do pacote fpp3.

Recomenda-se a especificação *hparmes*=c(NA,1,NA,0,0,0), tal especificação implica em tendência estocástica (d=1) e sazonalidade determinística da carga (P=0,Q=0,D=0) já modelada por meio de variáveis *dummy*. Da mesma forma, na previsão semanal, *hparsem1*=c(NA,1,NA,0,0,0) e *hparsem2*=c(NA,1,NA,0,0,0)) implicam em modelos de regressão dinâmica com tendência estocástica e sazonalidade determinística, modelada por 2*nharm* componentes harmônicas.

Durante a execução o programa exibe as etapas do processamento da previsão, conforme indicado no Quadro 2. Os destaques em amarelo indicam os coeficientes de regressão de todos os modelos ajustados, acompanhados de estatísticas do desempenho *insample* (MAD, MAPE, RMSE e UTheil). As previsões semanais e mensais conciliadas são destacadas em verde.

Quadro 2. Execução do modelo 6 do ForecastPMO

```
 [1] "ForecastPMO VERSAO 1.0"
 [1] "======================== Opcoes de execucao ====================="
 [1] "PMO REV0"
 [1] "Previsao da carga semanal com regressao dinamica"
 [1] "Modelos de regressao dinamica semanal com 6 componentes harmonicas"
 [1] "previsao da carga mensal com regressao dinamica"
 [1] "Dados em dataframe"
 [1] "Temperatura maxima no modelo de previsao semanal"
 [1] "Mensagem: Horizonte de previsao informado 2024-03-31"
 [1] "Mensagem: Horizonte de previsao alterado para 2024-04-05"
 [1] "======================== Leitura de dados ======================="
 [1] "Leitura do data.frame com dados do horizonte de previsao"
 [1] "Leitura do data.frame com dados de carga"
 [1] "Leitura do data.frame com dados de feriados"
 [1] "Leitura do data.frame com historico das variaveis exogenas"
 [1] "Leitura do data.frame com previsoes das variaveis exogenas"
 [1] "merge de dados historicos e previsoes concluido"
 [1] "leitura de dados concluida"
 [1] "======== PREVISAO DA CARGA SEMANAL COM REGRESSAO DINAMICA ========"
 [1] "== Primeiro modelo reg. dinamica para previsao da carga semanal =="
# A tibble: 11 × 6
   .model       term                      estimate std.error statistic  p.value
   <chr>        <chr>                        <dbl>     <dbl>     <dbl>    <dbl>
 1 ARIMA(modelo) ar1                         0.204    0.0938     2.18  2.99e- 2
 2 ARIMA(modelo) ma1                        -0.729    0.0611   -11.9   1.89e-28
 3 ARIMA(modelo) tmax_sem                  666.      26.5       25.2   4.61e-86
 4 ARIMA(modelo) Holiday                 -1015.      88.6      -11.5   1.16e-26
 5 ARIMA(modelo) ultima_semana           -2528.     284.        -8.90  1.72e-17
 6 ARIMA(modelo) fourier(K = nharm)C1_52    84.2    173.         0.487 6.26e- 1
 7 ARIMA(modelo) fourier(K = nharm)S1_52  1190.     177.         6.72  5.87e-11
 8 ARIMA(modelo) fourier(K = nharm)C2_52   -68.6    101.        -0.681 4.97e- 1
 9 ARIMA(modelo) fourier(K = nharm)S2_52  -419.     104.        -4.01  7.04e- 5
10 ARIMA(modelo) fourier(K = nharm)C3_52   246.      80.7        3.04  2.47e- 3
11 ARIMA(modelo) fourier(K = nharm)S3_52  -181.      79.9       -2.27  2.38e- 2
[1] "PERFORMANCE PRIMEIRA REG.DINAMICA PREVISAO SEMANAL -> MAD MW = 606.75 / MAPE% = 1.53 / RMSE MW = 823.23 / U-Theil = 0.5"
[1] "==== Segundo modelo de regressao dinamica para previsao da carga semanal ===="
# A tibble: 12 × 6
   .model          term                     estimate std.error statistic  p.value
   <chr>           <chr>                       <dbl>     <dbl>     <dbl>    <dbl>
 1 equacao$equacao ar1                         0.263    0.0789     3.33  9.48e- 4
 2 equacao$equacao ma1                        -0.794    0.0499   -15.9   5.08e-45
 3 equacao$equacao frio                     -987.     142.        -6.94  1.52e-11
 4 equacao$equacao quente                   2142.     137.        15.7   6.95e-44
 5 equacao$equacao Holiday                 -1036.     109.        -9.52  1.40e-19
 6 equacao$equacao ultima_semana           -2419.     328.        -7.37  8.94e-13
 7 equacao$equacao fourier(K = nharm)C1_52   347.     183.         1.90  5.88e- 2
 8 equacao$equacao fourier(K = nharm)S1_52  1673.     186.         8.99  8.63e-18
 9 equacao$equacao fourier(K = nharm)C2_52   -92.8    116.        -0.799 4.25e- 1
10 equacao$equacao fourier(K = nharm)S2_52  -704.     119.        -5.93  6.35e- 9
11 equacao$equacao fourier(K = nharm)C3_52   206.      98.3        2.10  3.67e- 2
12 equacao$equacao fourier(K = nharm)S3_52  -148.      97.9       -1.51  1.32e- 1
[1] "PERFORMANCE SEGUNDA REG.DINAMICA PREVISAO SEMANAL -> MAD MW = 741.85 / MAPE% = 1.86 / RMSE MW = 1009.61 / U-Theil = 0.6"
[1] "=========== PREVISAO DA CARGA MENSAL COM REG.DINAMICA ==========="
[1] "====     Modelo de regressao dinamica para previsao da carga mensal      ===="
[1] "====  nao usa carga acumulada parcial mensal como variavel explicativa   ===="
Using `year month` as index variable.
# A tibble: 14 × 6
   .model          term           estimate std.error statistic  p.value
```

```
   <chr>           <chr>              <dbl>     <dbl>     <dbl>    <dbl>
 1 equacao$equacao ma1              -0.219     0.103     -2.13 3.53e- 2
 2 equacao$equacao ma2              -0.284     0.108     -2.64 9.62e- 3
 3 equacao$equacao ndiasuteis_mes   226.       78.3       2.89 4.77e- 3
 4 equacao$equacao season()year2   1361.      408.        3.34 1.21e- 3
 5 equacao$equacao season()year3    687.      479.        1.43 1.55e- 1
 6 equacao$equacao season()year4  -1293.      500.       -2.59 1.12e- 2
 7 equacao$equacao season()year5  -3385.      504.       -6.72 1.31e- 9
 8 equacao$equacao season()year6  -4091.      510.       -8.02 2.52e-12
 9 equacao$equacao season()year7  -4417.      514.       -8.60 1.49e-13
10 equacao$equacao season()year8  -3748.      525.       -7.15 1.74e-10
11 equacao$equacao season()year9  -1555.      504.       -3.09 2.65e- 3
12 equacao$equacao season()year10 -1200.      491.       -2.45 1.63e- 2
13 equacao$equacao season()year11 -1242.      485.       -2.56 1.20e- 2
14 equacao$equacao season()year12 -1260.      382.       -3.30 1.38e- 3
[1] "PERFORMANCE REG.DINAMICA PREVISAO MENSAL -> MAD MW = 740.44 / MAPE% = 1.84 / RMSE MW = 987.73 / U-Theil = 0.61"
[1] "== RECONCILIA PREVISOES SEMANAIS E MENSAL PARA O PRIMEIRO MES ==="
[1] "Reconcilia previsoes semanais e mensal para o primeiro mes pelo metodo MINT"
[1] "====================== GERANDO RELATORIOS ======================"
[1] "============ Previsoes Mensais da Carga Global MW ============="
  janeiro/2024 fevereiro/2024      março/2024
      45552.50       45747.60       46282.22
[1] "==== Previsoes da Carga Global MW - abertas para o primeiro mes ===="
                MW Dias
2024-02-01 46629.49    1
2024-02-02 48409.23    1
2024-02-09 45595.74    7
2024-02-16 44920.19    7
2024-02-23 46016.56    7
2024-02-29 45985.70    6
fevereiro  45747.60   29
[1] "============ Previsoes Semanais da Carga Global MW ============="
2024-02-02 2024-02-09 2024-02-16 2024-02-23 2024-03-01 2024-03-08 2024-03-15
  45033.21   45595.74   44920.19   46016.56   45985.70   45740.48   45523.24
[1] "Execucao realizada com sucesso"
```

Ademais, o programa gera os *data.frames* e arquivos CSV indicados na Tabela 6. Os arquivos CSV são gerados no diretório informado em *dirout* apenas se a opção *grafico* estivar marcada com 1. No caso dos modelos de regressão dinâmica (modelos 2,4,5,6,7 e 10), o programa também grava no diretório *dirout* os aquivos CSV listados na Tabela 7, cada um deles contendo os dados usados no ajuste de um dos modelos de regressão dinâmica.

Tabela 6. Resultados (previsões) em *data.frames* e arquivos CSV gerados pelo ForecastPMO

Nome do data.frame	Nome do arquivo CSV	Conteúdo
previsao_mensal	ForecastPMO_previsao_mensal_carga_global.csv	Previsões da carga mensal
primeiro_mes_aberto	ForecastPMO_previsao_carga_global_mes_1_aberta.csv	Previsões da carga para o primeiro mês, desagregadas por semana operativa
previsao_semanal	ForecastPMO_previsao_semanal_carga_global.csv	Previsões da carga semanal para as seis primeiras semanas operativas do horizonte de previsão

Tabela 7. Arquivos CSV com os dados usados no ajuste dos modelos de regressão dinâmica

Nome do arquivo CSV	Conteúdo
weekly_data_dynamic_reg_first_week.csv	Dados usados no ajuste do modelo de regressão dinâmica para previsão da carga na primeira semana do horizonte
weekly_data_dynamic_reg.csv	Dados usados no ajuste do modelo de regressão dinâmica para previsão da carga semanal, a partir da segunda semana do horizonte
monthly_data_dynamic_reg_model.csv	Dados usados no ajuste do modelo de regressão dinâmica para previsão da carga mensal

Além dos data.frames listados na Tabela 6, o ForecastPMO gera os seguintes data.frames acessíveis no ambiente R:

- tipo_estudo: indica se REV0 ou demais revisões do PMO
- previsao_mensal: previsões mensais
- previsao_semanal: previsões semanais
- primeiro_mes_aberto: previsões semanais para o primeiro mês do horizonte de previsão
- modelo_mensal: informa o tipo de modelagem usada na previsão mensal
- modelo_semanal: informa o tipo de modelagem usada na previsão semanal
- serie_mensal: histórico da carga mensal acompanhado das respectivas estimativas
- serie_semanal: histórico da carga semanal acompanhado das respectivas estimativas
- metricas_insample_semanal: MAD, MAPE, RMSE e UTheil *insample* do ajuste do modelo semanal
- metricas_insample_mensal: MAD, MAPE, RMSE e UTheil *insample* do ajuste do modelo mensal
- PREVISOES_SEMANAIS_ANTES: previsões semanais antes da conciliação com as previsões mensais
- PREVISOES_MENSAIS_ANTES: previsões mensais antes da conciliação com as previsões semanais
- lista_feriados_semanais: indicação de feriados nas semanas do horizonte de previsão, informação utilizada na combinação de previsões

Para acessar os *data.frames* contendo resultados insira *$nome* do *data.frame* após o objeto de saída, conforme ilustrado no Quadro 3 para o exemplo em tela.

Quadro 3. Acessando os *data.frames* gerados pelo ForecastPMO

```
resultado6$previsao_mensal
  janeiro/2024 fevereiro/2024     março/2024
      45552.50       45747.60       46282.22

resultado6$primeiro_mes_aberto
                 MW Dias
2024-02-01 46629.49    1
2024-02-02 48409.23    1
2024-02-09 45595.74    7
2024-02-16 44920.19    7
2024-02-23 46016.56    7
2024-02-29 45985.70    6
fevereiro  45747.60   29

resultado6$previsao_semanal
2024-02-02 2024-02-09 2024-02-16 2024-02-23 2024-03-01 2024-03-08 2024-03-15
  45033.21   45595.74   44920.19   46016.56   45985.70   45740.48   45523.24
```

A opção *grafico*=1 também gera as Figuras 16, 17 e 18 que ilustram as cargas observadas (pontos) e estimadas (em azul) no quadrante superior esquerdo, a função de autocorrelação parcial dos resídulos do modelo de previsão (ACF), a função de autocorrelação parcial dos resíduos (PACF) e histograma dos resíduos. Os gráficos gerados são úteis na anáiise dos resíduos dos modelos de previsão e permitem identificar problemas nas especificações adotadas.

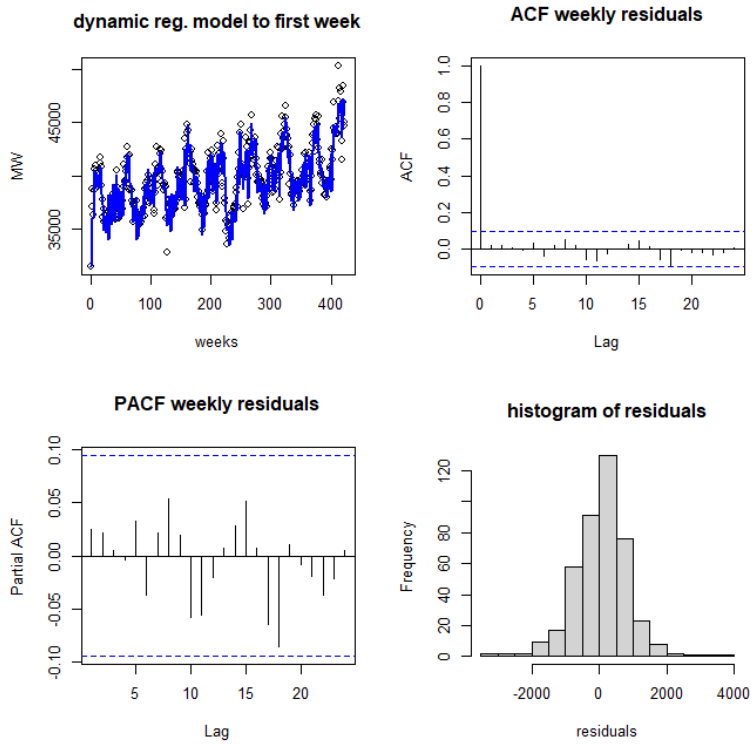


Figura 16. Resultados da regressão dinâmica para previsão da carga na primeira semana do horizonte

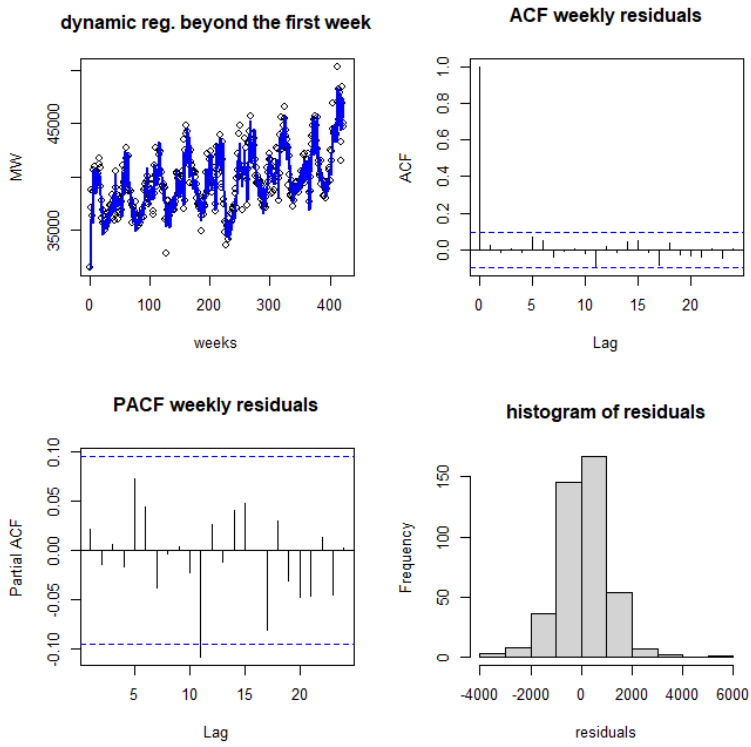


Figura 17. Resultados da regressão dinâmica para previsão da carga nas demais semanas do horizonte

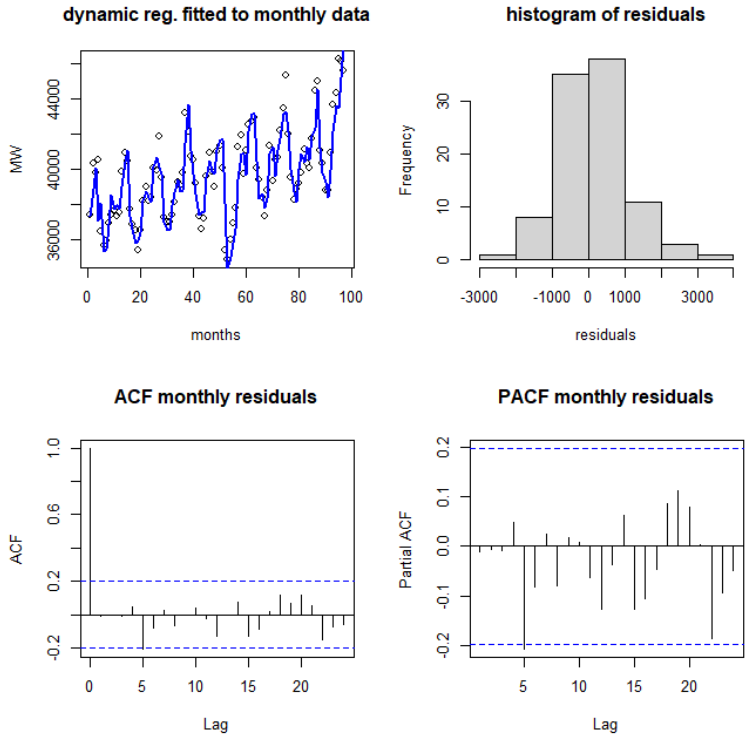


Figura 18. Resultados do modelo de regressão dinâmica para previsão da carga mensal

6.3.2 Ajuste de modelos SVM

Neste outro exemplo o *previsorpmo* gera as previsões semanais e mensais com SVM (*modelo* 0). No caso da previsão mensal com SVM, caso deseje especificar as defasagens (*lags*) manualmente, informe o parâmetro *hparmes*, por exemplo, *hparmes*=c(1,6,12,24). Assim, o SVM entenderá que a carga no mês *M* depende da carga nos meses *M*-1, *M*-6, *M*-12 e *M*-24. Caso o parâmetro *hparmes* não seja informado o programa irá considerar a opção *default*, i.e., a seleção automática dos *lags* a partir da função de autocorrelação parcial da série temporal da carga mensal. Similarmente, no previsor semanal com SVM, caso deseje especificar as defasagens manualmente, informe o parâmetro *hparsem1*, por exemplo,

hparsem1=c(1,51,52). Para a seleção automática dos *lags* semanais não informe *hparsem1*. Vale destacar que o parâmetro *hparsem2* tem efeito apenas no ajuste de modelos de regressão dinâmica.

Neste exemplo, optou-se pela seleção automática dos valores passados da carga (*lags*) nos modelos SVM para as previsões mensal e semanal, a opção *default*, logo os parâmetros *hparmes* e *hparsem1* não precisam ser informados na chamada do *previsorpmo*. Ademais, considerou-se a temperatura média (*tipotemp*=1) e as opções *default pandemia*=0 e *grafico*=0 (sem gráficos e sem a gravação de arquivos CSV). Como no exemplo anterior, os dados estão no formato data.frame (*tipoinput*=1) e as previsões são para REV0 (*tipoestudo*=1) e conciliadas pelo método MinT (*conciliar*=1).

Quadro 4. Exemplo de *script* para execução do modelo 0 do ForecastPMO

```
resultado0=previsorpmo(dirinput,dirout,modelo=0,tipoinput=1,tipotemp=1,tipoestudo=1,conciliar=1)
```

Nota: (1) o que aparece após # é um comentário ignorado pelo R, (2) os parâmetros omitidos indicam que foram consideradas as opções *default*.

Durante a execução o programa exibe as etapas do processamento da previsão, conforme indicado no Quadro 5. Os destaques em amarelo indicam os *lags* da carga, selecionados de forma automática, nos modelos SVM semanais e mensal. As estatísticas do desempenho *insample* (MAD, MAPE, RMSE e UTheil) para a previsão uma semana à frente e um mês a frente são destacadas em verde.

Quadro 5. Execução do ForecastPMO

```
 [1] "ForecastPMO VERSAO 1.0"
 [1] "======================== Opcoes de execucao ===================="
 [1] "PMO REV0"
 [1] "Previsao da carga semanal com SVM"
 [1] "previsao da carga mensal com SVM"
 [1] "Dados em dataframe"
 [1] "Temperatura media no modelo de previsao semanal"
 [1] "Mensagem: Horizonte de previsao informado 2024-03-31"
 [1] "Mensagem: Horizonte de previsao alterado para 2024-04-05"
 [1] "======================== Leitura de dados ======================="
 [1] "Leitura do data.frame com dados do horizonte de previsao"
 [1] "Leitura do data.frame com dados de carga"
 [1] "Leitura do data.frame com dados de feriados"
 [1] "Leitura do data.frame com historico das variaveis exogenas"
 [1] "Leitura do data.frame com previsoes das variaveis exogenas"
 [1] "merge de dados historicos e previsoes concluido"
 [1] "leitura de dados concluida"
 [1] "================ PREVISAO DA CARGA SEMANAL COM SVM ==============="
 [1] "lags definidos automaticamente para a primeira semana"
  [1]  1  2  3  5  9 10 15 43 51 53
 [1] "lags definidos automaticamente para as demais semanas"
 [1]  1  2 51
 [1] "previsao 1 semana a frente"
 [1] "previsao 2 semana a frente"
 [1] "previsao 3 semana a frente"
 [1] "previsao 4 semana a frente"
 [1] "previsao 5 semana a frente"
 [1] "previsao 6 semana a frente"
 [1] "PERFORMANCE SVM PREVISAO SEMANAL -> MAD MW = 573.79 / MAPE% = 1.45 / RMSE MW = 784.63 / U-Theil = 0.47"
 [1] "================ PREVISAO DA CARGA MENSAL COM SVM ==============="
 [1] "lags definidos automaticamente"
 [1]  1  2 10 11 12 13 23 24 25
 [1] "PERFORMANCE SVM PREVISAO MENSAL -> MAD MW = 864.03 / MAPE% = 2.14 / RMSE MW = 1195.65 / U-Theil =  0.71"
 [1] "== RECONCILIA PREVISOES SEMANAIS E MENSAL PARA O PRIMEIRO MES ==="
 [1] "Reconcilia previsoes semanais e mensal para o primeiro mes pelo metodo MINT"
 [1] "====================== GERANDO RELATORIOS ======================="
 [1] "============= Previsoes Mensais da Carga Global MW ==============="
  janeiro/2024 fevereiro/2024     março/2024
      45552.50       45294.64       46499.76
 [1] "==== Previsoes da Carga Global MW - abertas para o primeiro mes ===="
                  MW Dias
2024-02-01 47615.36    1
2024-02-02 51859.75    1
2024-02-09 45317.05    7
2024-02-16 43693.35    7
2024-02-23 45242.49    7
2024-02-29 45716.54    6
fevereiro  45294.64   29
 [1] "============ Previsoes Semanais da Carga Global MW ==============="
2024-02-02 2024-02-09 2024-02-16 2024-02-23 2024-03-01 2024-03-08 2024-03-15
  45033.21   45317.05   43693.35   45242.49   45716.54   45569.54   45587.25
 [1] "Execucao realizada com sucesso"
```

Para acessar os *data.frames* contendo resultados insira *$nome* do *data.frame* após o objeto de saída, conforme ilustrado no Quadro 6.

Quadro 6. Acessando os *data.frames* gerados pelo ForecastPMO

```
resultado0$previsao_mensal
  janeiro/2024 fevereiro/2024     março/2024
      45552.50       45294.64       46499.76

resultado0$primeiro_mes_aberto
                  MW Dias
2024-02-01 47615.36    1
2024-02-02 51859.75    1
2024-02-09 45317.05    7
2024-02-16 43693.35    7
2024-02-23 45242.49    7
```

```
2024-02-29 45716.54     6
fevereiro  45294.64    29

resultado0$previsao_semanal
2024-02-02 2024-02-09 2024-02-16 2024-02-23 2024-03-01 2024-03-08 2024-03-15
  45033.21   45317.05   43693.35   45242.49   45716.54   45569.54   45587.25
```

6.3.3 Ajuste de modelos SARIMA/ETS

Neste caso, a previsão mensal é realizada por um modelo SARIMA e a previsão semanal por um modelo ETS (modelo 11). Os hiperparâmetros do SARIMA (p,d,q,P,D,Q) podem ser identificados automaticamente ou especificados manualmente por meio do parâmetro *hparmes*, por exemplo, *hparmes*=c(0,1,1,0,1,1) é a configuração para a série *airline*. Para a seleção automática dos hiperparâmetros não informe *hparmes*. A previsão semanal realizada pelo modelo ETS não considera as informações em *hparsem1* e *hparsem2*. A seguir, no Quadro 7 apresenta-se o *script* para previsão com base nos modelos SARIMA e ETS, no qual foi considerado o pré-tratamento de dados do efeito da pandemia (*pandemia*=1). Os modelos SARIMA e ETS são univariados então o parâmetro *tipotemp* não precisa ser especificado.

Quadro 7. Exemplo de *script* para execução do modelo 11 do ForecastPMO

```
resultado11=previsorpmo(dirinput,dirout,modelo=11,tipoinput=1,tipoestudo=1,conciliar=1,pandemia=1,grafico=1)
```

Nota: (1) o que aparece após # é um comentário ignorado pelo R, (2) os parâmetros omitidos indicam que foram consideradas as opções *default*.

Durante a execução o programa exibe as etapas do processamento da previsão, conforme indicado no Quadro 8. A especificação do modelo ETS obtida de forma automática pelo fpp3 está destacada em amarelo. Já a especificação do modelo SARIMA está destacada em verde, juntamente com as métrica de desempeho *insample*.

Quadro 8. Execução do ForecastPMO

```
 [1] "ForecastPMO VERSAO 1.0"
 [1] "========================= Opcoes de execucao ====================="
 [1] "PMO REV0"
 [1] "Previsao da carga semanal com Holt-Winters"
 [1] "previsao da carga mensal com modelo SARIMA"
 [1] "Dados em dataframe"
 [1] "Mensagem: Horizonte de previsao informado 2024-03-31"
 [1] "Mensagem: Horizonte de previsao alterado para 2024-04-05"
 [1] "======================= Leitura de dados ======================="
 [1] "Leitura do data.frame com dados do horizonte de previsao"
 [1] "Leitura do data.frame com dados de carga"
 [1] "Leitura do data.frame com dados de feriados"
 [1] "merge de dados historicos e previsoes concluido"
 [1] "leitura de dados concluida"
 [1] "======== PREVISAO DA CARGA SEMANAL COM HOLT WINTERS ========"
 [1] "==== Previsao da carga semanal com Holt-Winters ===="
Series: carga_sem
Model: STL decomposition model
Combination: season_adjust + season_year

====================================

Series: season adjust
Model: ETS(M,N,N)
  Smoothing parameters:
    alpha = 0.3530487

  Initial states:
     l[0]
 36089.77

  sigma^2:  0.001

     AIC     AICc      BIC
8577.563 8577.620 8589.705

Series: season_year
Model: SNAIVE

sigma^2: 11202.8771

[1] "PERFORMANCE HOLT-WINTERS PREVISAO SEMANAL -> MAD MW = 926.15 / MAPE% = 2.3 / RMSE MW = 1226.35 / U-Theil = 0.71"
[1] "mensagem: realizado tratamento do efeito da pandemia"
[1] "========== PREVISAO DA CARGA MENSAL COM BOX & JENKINS =========="
[1] "==== Modelo SARIMA para previsao da carga mensal ===="
Using `year_month` as index variable.
[1] "mensagem: realizado tratamento do efeito da pandemia"
# A tibble: 3 × 6
  .model          term     estimate std.error statistic  p.value
  <chr>           <chr>       <dbl>     <dbl>     <dbl>    <dbl>
1 equacao$equacao ar1         0.493    0.0986      5.00 3.08e- 6
2 equacao$equacao sma1       -0.797    0.181      -4.40 3.17e- 5
3 equacao$equacao constant  338.      45.2         7.48 6.17e-11
[1] "PERFORMANCE SARIMA PREVISAO MENSAL -> MAD MW = 685.98 / MAPE% = 1.69 / RMSE MW = 946.75 / U-Theil =  0.6"
[1] "== RECONCILIA PREVISOES SEMANAIS E MENSAL PARA O PRIMEIRO MES ==="
[1] "Reconcilia previsoes semanais e mensal para o primeiro mes pelo metodo MINT"
[1] "==================== GERANDO RELATORIOS ======================="
[1] "============= Previsoes Mensais da Carga Global MW ============="
  janeiro/2024 fevereiro/2024     março/2024
      45552.50       45781.97       45827.72
[1] "==== Previsoes da Carga Global MW - abertas para o primeiro mes ===="
               MW Dias
2024-02-01 45921.91    1
2024-02-02 45932.70    1
2024-02-09 45405.94    7
```

```
2024-02-16 46402.07    7
2024-02-23 45393.92    7
2024-02-29 45901.50    6
fevereiro  45781.97   29
[1] "============ Previsoes Semanais da Carga Global MW =============="
2024-02-02 2024-02-09 2024-02-16 2024-02-23 2024-03-01 2024-03-08 2024-03-15
  45033.21   45405.94   46402.07   45393.92   45901.50   46786.14   46451.85
[1] "Execucao realizada com sucesso"
```

Dado que *grafico*=1, o programa gera os *data.frames* e arquivos CSV indicados na Tabela 8. No caso do modelo SARIMA (modelos 3,7 e 11), o programa também grava no diretório *dirout* o aquivo monthly_data_SARIMA.csv e gera a Figura 19.

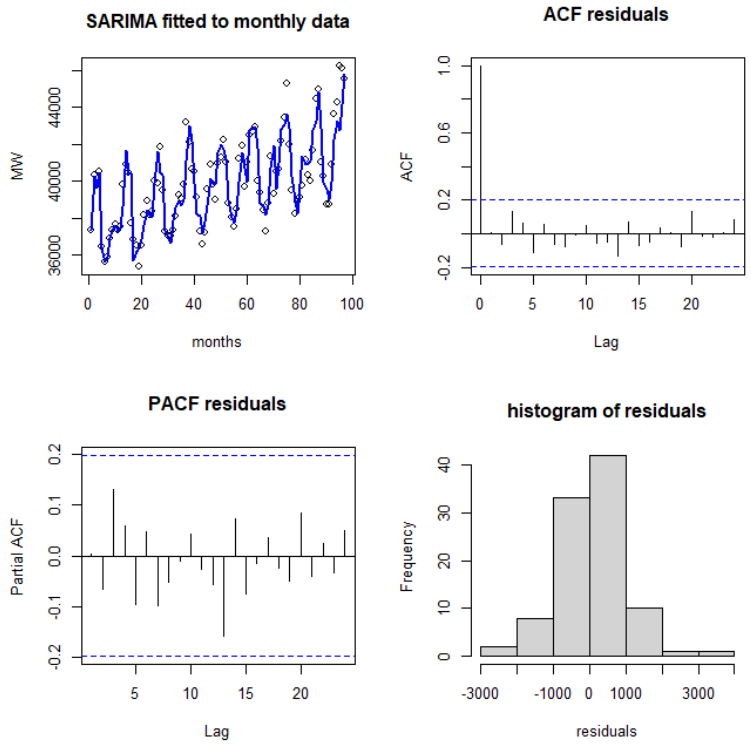


Figura 19. Análise dos resíduos do modelo SARIMA para previsão da carga mensal

Para acessar os *data.frames* contendo resultados insira *$nome* do *data.frame* após o objeto de saída, conforme ilustrado no Quadro 9.

Quadro 9. Acessando os *data.frames* gerados pelo ForecastPMO

```
resultado11$previsao_mensal
  janeiro/2024 fevereiro/2024     março/2024
      45552.50       45781.97       45827.72

resultado11$primeiro_mes_aberto
                  MW Dias
2024-02-01 45921.91    1
2024-02-02 45932.70    1
2024-02-09 45405.94    7
2024-02-16 46402.07    7
2024-02-23 45393.92    7
2024-02-29 45901.50    6
fevereiro  45781.97   29

resultado11$previsao_semanal
2024-02-02 2024-02-09 2024-02-16 2024-02-23 2024-03-01 2024-03-08 2024-03-15
  45033.21   45405.94   46402.07   45393.92   45901.50   46786.14   46451.85
```

6.4 Execução da combinação de previsões

Os três exemplos descritos na seção 6.3 resultaram na criação de três listas denominadas resultado6, resultado0 e resultado11. Estas listas encapsulam dados e previsões semanais/mensais obtidas pelos

modelos 6, 0 e 11, respectivamente. Ao invés de escolher as previsões oriundas de um dos três modelos, pode-se combiná-las por meio da função *combinaprev* do ForecastPMO, cuja finalidade é extrair as previsões das listas supracitadas e integrá-las em uma única previsão, utilizando um dos algoritmos descritos na seção 4. Os parâmetros da função *combinaprev* são apresentados na Tabela 8.

Tabela 8. Função combinaprev

combinaprev(baselearners,tipoprevisao,metcombina,conciliar)

baselearners	lista de objetos gerados pela execução de diferentes modelos do ForecastPMO
tipoprevisao	• 1, combina as previsões individuais previamente conciliadas (previsões finais) • 0, combina as previsões individuais não conciliadas
metcombina	• 0, mediana das previsões semanais e mediana das previsões mensais • 1, média das previsões semanais e média das previsões mensais • 2, média ponderada das previsões pelo inverso da variância do erro (Bates e Granger) • 3, *stacking* com meta modelo SVM
Conciliar	se REV0: • 0, ajusta as previsões combinadas semanais do primeiro mês para que a média seja igual a previsão combinada mensal • 1, concilia as previsões combinadas pelo método do traço mínimo (MinT *Minimum Trace*) • 2, ajusta a previsão combinada mensal do primeiro mês para que seja igual a média das previsões combinadas semanais se revisao ordinária: • 0, ajusta a previsão combinada mensal do mês corrente para que seja igual a média das previsões combinadas semanais • 1 concilia as previsões combinadas pelo metodo MinT

A seguir, no Quadro 10, apresenta-se um *script* para combinação das previsões finais individuais (após a conciliação, i.e., *tipoprevisao*=1) por meio de *stacking* das previsões (*metcombina*=3), seguida de conciliação pelo método MinT (*conciliar*=1). Note que inicialmente os objetos gerados pelos modelos individuais são organizados na lista *baselearners*. A combinação é realizada na última linha com a chamada da função *combinaprev*.

Quadro 10. Exemplo de *script* para combinação de previsões pelo ForecastPMO

```
baselearners=list(resultado0,resultado6,resultado11)
previsao_combinada=combinaprev(baselearners,tipoprevisao=1,metcombina=3,conciliar=1)
```

Conforme indicado no Quadro 10, os resultados da execução da função *combinaprev* são armazenados na lista *previsao_combinada*, na qual podem ser acessados os resultados indicados na Tabela 9.

Tabela 9. Objetos gerados pela execução da função *combinaprev*

Nome do data.frame	Conteúdo
hist_baselearners_semanais	Matriz com os valores observados e estimativas semanais para o período histórico, calculadas pelos modelos selecionados em *baselearner*. Cada coluna guarda os resultados de um modelo e cada linha os valores para uma semana. Armazena o conjunto de dados usados no ajuste do meta-modelo que combina as previsões semanais.
hist_baselearners_mensais	Matriz com os valores observados e estimativas mensais para o período histórico, calculadas pelos modelos selecionados em *baselearner*. Cada coluna guarda os resultados de um modelo e cada linha os valores para um mês. Armazena o conjunto de dados usados no ajuste do meta-modelo que combina as previsões mensais.
prev_baselearners_semanais	Matriz com as previsões semanais individuais calculadas pelos modelos selecionados em *baselearner*. Cada coluna guarda as previsões de um modelo e cada linha os valores para uma semana.
prev_baselearners_mensais	Matriz com as previsões mensais individuais calculadas pelos modelos selecionados em *baselearner*. Cada coluna guarda as previsões de um modelo e cada linha os valores para um mês.
prev_comb_sem_ANTES_CONCILIA	Previsões semanais combinadas antes da conciliação com as previsões mensais

prev_comb_mes_ANTES_CONCILIA	Previsões mensais combinadas antes da conciliação com as previsões semanais
previsao_semanal	Previsões semanais combinadas e conciliadas em cada semana do horizonte de previsão
previsao_mensal	Previsões mensais combinadas e conciliadas em cada mês do horizonte de previsão

Conforme indicado no Quadro 10, os resultados da execução da função combinaprev são armazenados na lista previsao_combinada, na qual podem ser acessados os resultados indicados na Tabela 9. Para acessar os *data.frames* contendo as previsões combinadas insira *$nome* do *data.frame* após o objeto de saída, conforme ilustrado no Quadro 11.

Quadro 11. Acessando as previsões combinadas

```
previsao_combinada$previsao_mensal
  janeiro/2024 fevereiro/2024     março/2024
      45438.84       45751.86       46208.59

previsao_combinada$previsao_semanal
2024-02-02 2024-02-09 2024-02-16 2024-02-23 2024-03-01 2024-03-08 2024-03-15
  45606.16   46240.24   43764.76   46481.90   46697.20   45832.28   45874.51
```

Referências bibliográficas

Are, M.T., Okorie, P.U., Olarinoye, G.A. A review of short-term electrical load forecasting using ensemble stacking generalization with artificial neural network. Journal of Materials Engineering, Structures and Computation, 2(1), pp. 36-52, 2023

Baghel. M.; Ghosh, A.; Singh, N.K.; Singh, A.K. Short –Term Electric Load Forecasting Using SVR Implementing LibSVM Package and Python Code, Electrical, Computer and Electronics Engineering (UPCON), 2016 IEEE Uttar Pradesh Section International Conference on, 9-11 December, 2016

Bates, J.M., Granger, C.W.J. The combination of forecasts. Journal of the Operational Research Society 20(4), 451–468. 1969. DOI: 10.1057/jors.1969.103

Bento, P.M.R., Pombo, J.A.N., Calado, M.R.A., Mariano, S.J.P.S. Stacking Ensemble Methodology Using Deep Learning and ARIMA Models for Short-Term Load Forecasting. *Energies* 2021, *14*, 7378. https://doi.org/10.3390/en14217378

Chen, B.J.; Chang, M.W.; Lin, C.J. Load forecasting using support vector machines: a study on EUNITE Competition 2001, IEEE Transactions on power systems, v. 19, n. 4, November 2004.

Hamel, L. Knowledge discovery with support vector machines, Wiley, 2009.

Hassani, H., Mahmoudvand, R. Singular Spectrum Analysls, Palgrave MacMillan, 2018.

Hong,W.C. Electric load forecasting by support vector model, Applied Mathematical Modelling Volume 33, Issue 5, Pages 2444-2454, May 2009.

Hyndman, R.J.; Athanasopoulos, G. Forecasting Principles and Practice, OTexts, 3rd edition, 2021.

Makridakis, S.; Spiliotis, E.; Assimakopoulos, V. Statistical and machine learning forecasting methods: concerns and ways forward. PLoS ONE, v. 13, n. 3, p. 1-26, 2018.

Morettin, P.A.; Toloi, C. M. Análise de Séries Temporais. 2 ed. São Paulo: Atual, 2006.

Pessanha, J.F.M.; Almeida, V.A. Ajuste sazonal diário no cálculo de series temporais de cargas elétricas livres dos efeitos calendário e temperature. LIII Simpósio Brasileiro de Pesquisa Operacional, João Pessoa, 2021.

R Core Team, R: A language and environment for statistical computing. R Foundation for Statistical Computing, Vienna, Austria. URL https://www.R-project.org/, 2017

Smola, A.J; Scholkopf, B. A Tutorial on Support Vector Regression, Journal Statistics and Computing, Volume 14 Issue 3, Pages 199-222, August 2004.

Souza, R.C.; Camargo, M.E. Análise e previsão de séries temporais: os modelos ARIMA. SEDIGRAF, Ijuí, 2004

Sujan Reddy A., Akashdeep S., Harshvardhan R., Sowmya Kamath S., Stacking Deep learning and Machine learning models for short-term energy consumption forecasting, Advanced Engineering Informatics, Volume 52, 101542, 2022.

Tan, Z., Zhang, J., He, Y., Zhang, Y, Xiong, G., Liu, Y. Short-term load forecasting base on integration of SVR and stacking, IEEE Access, v. 8, pp. 227719 – 227728, 2020.

Vapnik, V.N.; Boser, E.B.; Guyon, I.M.; Training Algorithm for Optimal Margin Classiers, Proceedings of the fifth annual workshop on Computational learning theory, Pages 144-152, Pennsylvania, July 1992.

Wang, X., Hyndman, R.J., Li, F., Kang, Y. Forecast combinations: an over 50-year review, International Journal of Forecasting, v. 39, n. 4, October-December, pp. 1518-1547, 2023.

Yadav, S.; Shukla, S. Analysis of k-Fold Cross-Validation over Hold-Out Validation on Colossal Datasets for Quality Classification, Advanced Computing (IACC), 2016 IEEE 6th International Conference on, February 2016.

Zhang, H., Zhu, T. Stacking Model for Photovoltaic-Power-Generation Prediction. *Sustainability* 2022, *14*, 5669. https://doi.org/10.3390/su14095669